Yapay Zeka ve Veri Mühendisliği Bölümü

YZVM102 Veri Bilimine Giriş
2025-2026 Bahar Yarıyılı

Hafta 7 – Denetimli Öğrenmeye Giriş-II
Introduction to Supervised Learning

Doç. Dr. Musa AYDIN

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- **Destek Vektör Makineleri (Support Vector Machines-SVMs)** sınıflandırma ve regresyon problemlerinde kullanılan gözetimli öğrenme yöntemlerinden biridir.
- Bir düzlem üzerine yerleştirilmiş noktaları ayırmak için bir doğru çizer. Bu doğrunun, iki sınıfının noktaları için de maksimum uzaklıkta olmasını amaçlar.

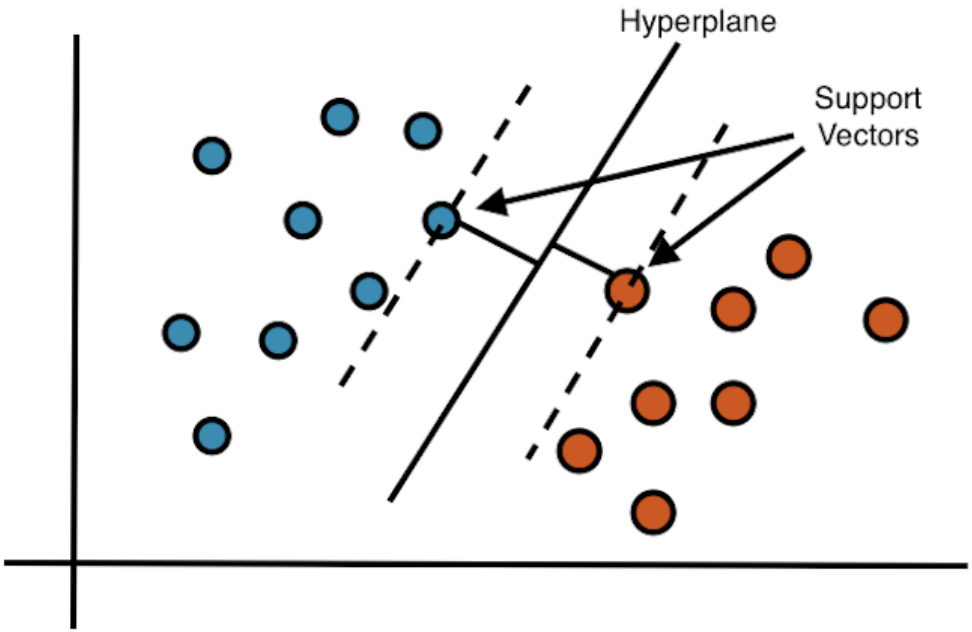

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- **Destek Vektör Makineleri (Support Vector Machines-SVMs):** Veri kümesini sınıflar arasında en iyi şekilde ayıran bir hiperdüzlemi bulmaya çalışır.
- SVM özellikle doğrusal olmayan veri kümeleri için etkilidir, çünkü Kernel yöntemini kullanarak veriyi daha yüksek boyutlu uzaylara dönüştürerek doğrusal olarak ayrılabilir bir yapı elde edilebilir.

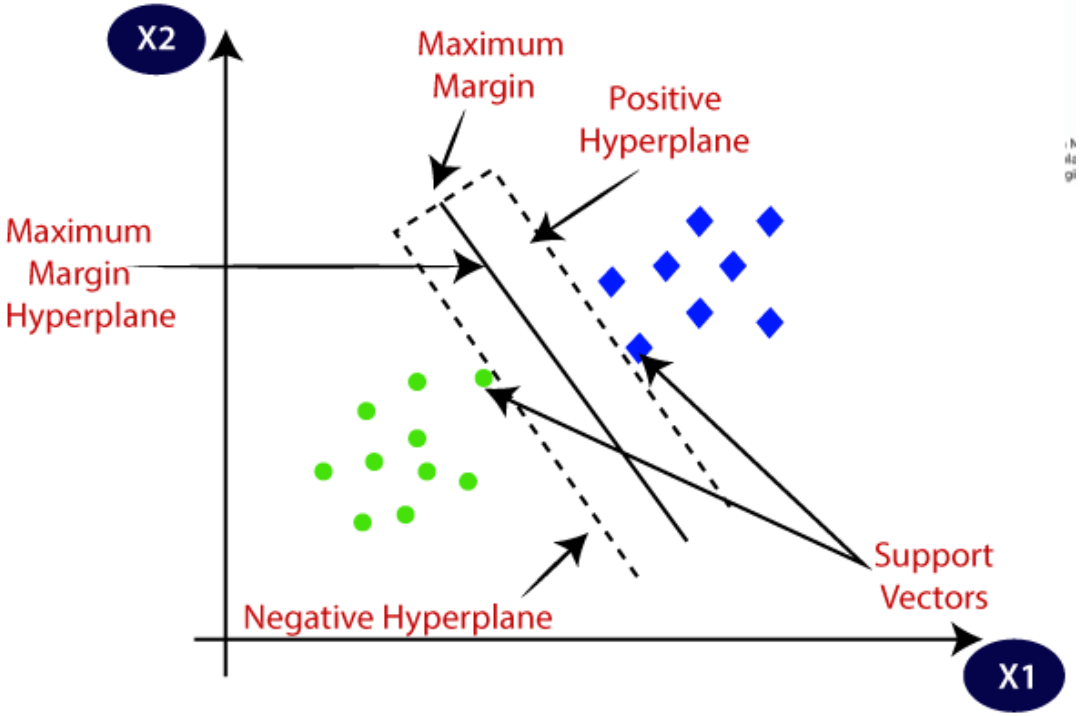

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- **Destek Vektör Makineleri (Support Vector Machines-SVMs):** Birbirine en yakın olan iki ayrı sınıfın iki farklı noktası support point-vector olarak belirlenir.
- Bir düzlem üzerine yerleştirilmiş noktaları ayırmak için bir doğru çizer. Bu doğrunun, iki sınıfının noktaları için de maksimum uzaklıkta olmasını amaçlar.

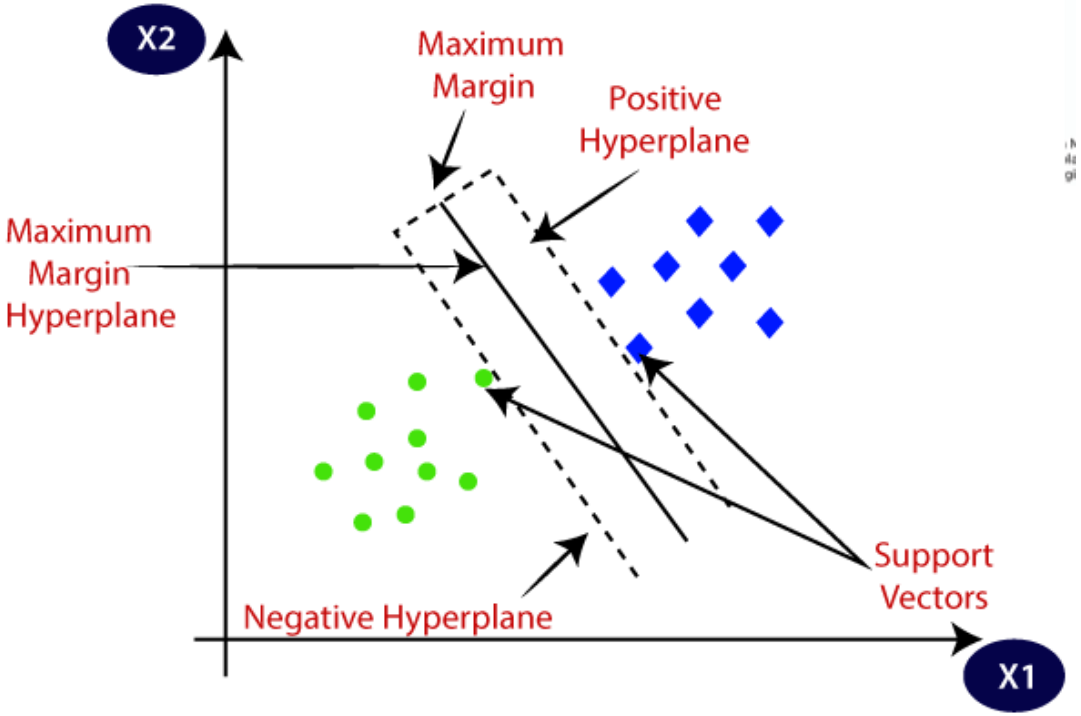

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- **Hiperdüzlem (Hyperplane):** Sınıfları birbirinden ayıran karar sınırıdır. 2 boyutlu uzayda bir doğru (çizgi), 3 boyutlu uzayda bir düzlem, daha yüksek boyutlarda ise hiperdüzlem adını alır.
- **Destek Vektörleri (Support Vectors):** Hiperdüzleme en yakın olan veri noktalarıdır. Sınırın (marjın) nerede çizileceğini bu noktalar belirler. Eğer diğer (uzaktaki) veri noktalarını silerseniz hiperdüzlem değişmez; ancak destek vektörlerini silerseniz hiperdüzlem tamamen değişir!
- **Marj (Margin):** Hiperdüzlem ile her iki sınıfın destek vektörleri arasındaki mesafedir. SVM'in temel amacı bu marjı **maksimize etmektir**.

Marjin ne kadar geniş olursa iki veya daha fazla sınıf o kadar iyi ayrıştırılır.

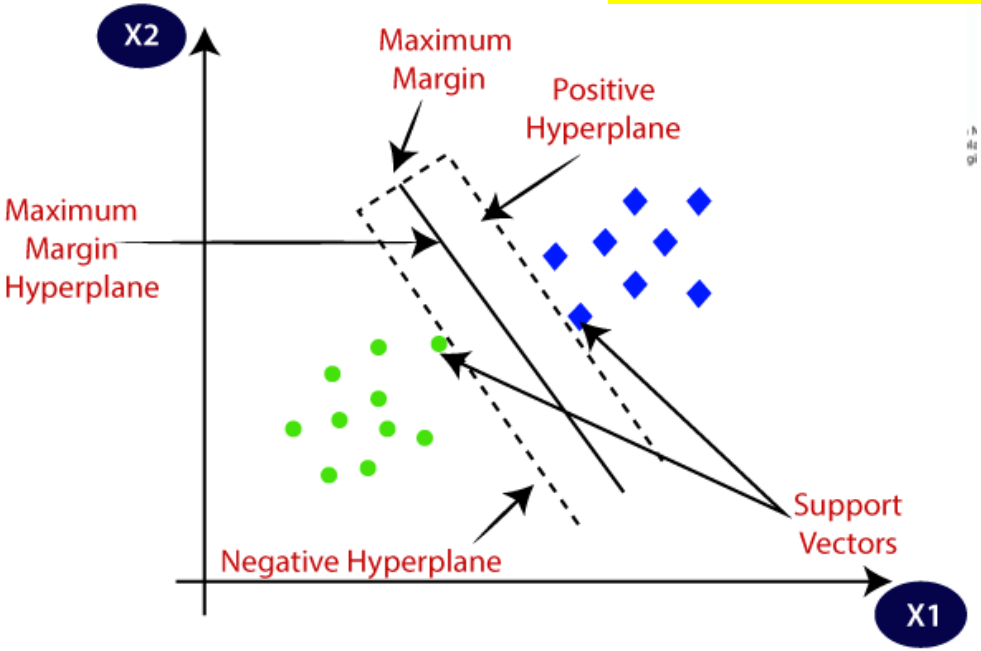

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- SVM-matematiksel tanımı:

Hiperdüzlemin denklemini şu şekilde tanımlayabiliriz:

$$w^T x + b = 0$$

Burada w (weight/ağırlık) düzleme dik olan vektörü, x veri noktasını, b ise sapmayı (bias) temsil eder.

İki sınıfın sınırlarını belirleyen destek vektörlerinin üzerinden geçen paralel doğruların denklemleri ise şöyledir:

- Sınıf 1 için sınır:

$$w^T x + b = 1$$

- Sınıf -1 için sınır:

$$w^T x + b = -1$$

$$\hat{y} = \begin{cases} 0 \text{ if } \mathbf{w}^T \cdot \mathbf{x} + b < 0, \\ 1 \text{ if } \mathbf{w}^T \cdot \mathbf{x} + b \geq 0 \end{cases}$$

Bu iki sınır (marj) arasındaki toplam geometrik mesafe şu formülle hesaplanır:

$$Marj = \frac{2}{||w||}$$

Optimizasyon Hedefi: Marjı maksimize etmek, matematiksel olarak $||w||$ değerini (yani ağırlık vektörünün büyüklüğünü) minimize etmek demektir. Bu, kısıtlı bir optimizasyon problemidir ve Lagrange Çarpanları kullanılarak çözülür.

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

- Sınıflandırmak istediğimiz veri setleri her zaman doğrusal olarak ayrılamayabiliyor. Bazen örneklerimiz Margin bölgesine girebilir. Bu sebeple, hard marjin ve soft marjin seçimi önem kazanıyor. Hard marjin ve Soft marjin verinin doğrusallığı ile alalı terimlerdir.

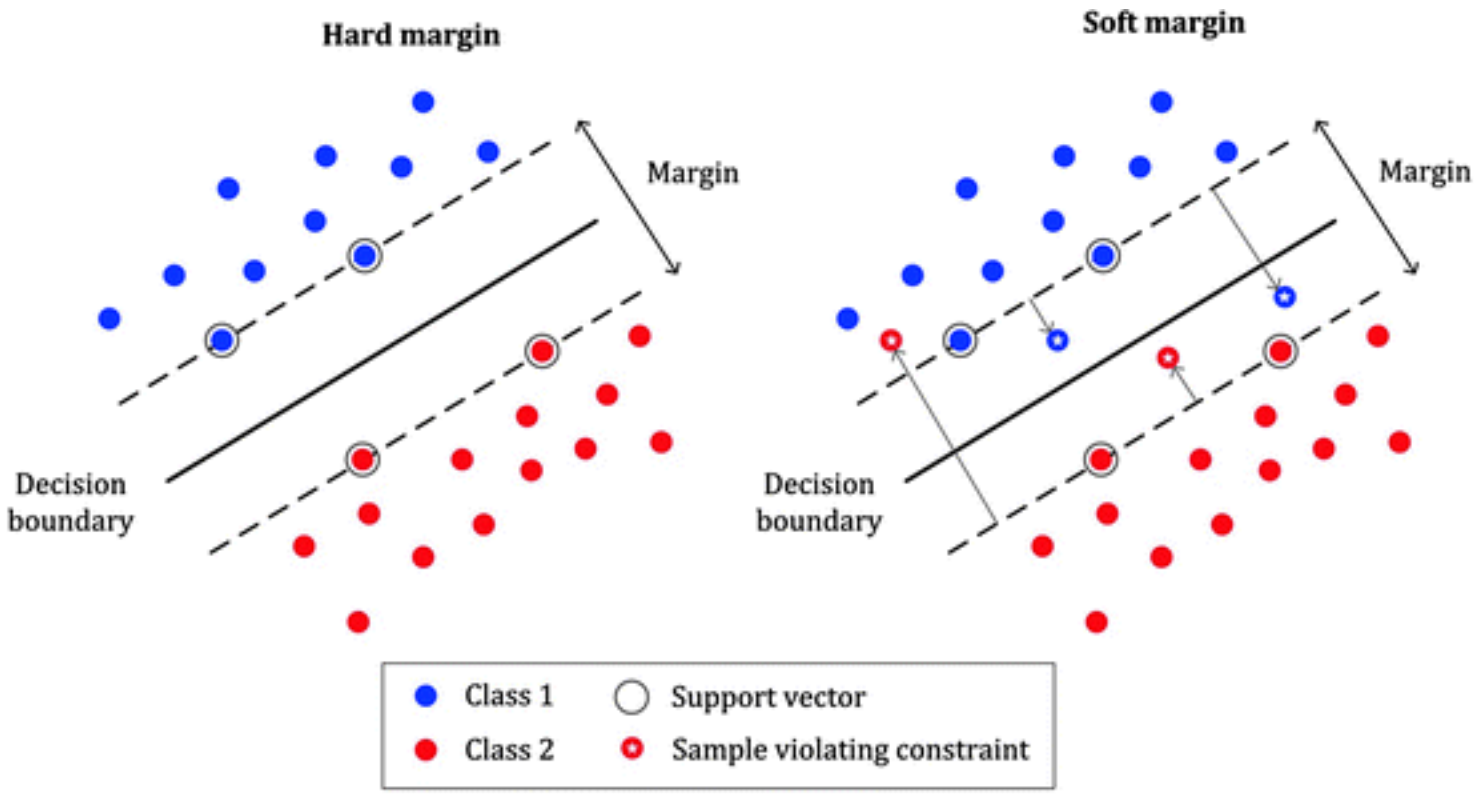

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

•**Hard Marjin:** Yalnızca veriler doğrusal olarak ayrılabiliyorsa çalışmakta ve aykırı değerlere karşı oldukça hassastır.

•**Soft Marjin:** Hard marjine göre toleransı daha yüksektir. Bu sebeple, eğitim verilerindeki bazı noktaların ayırma çizgisini ihmal etmesine izin verir. Amaç, marjin ihlallerini sınırlamak ve marjini dengeli tutabilmektir. Scikit-Learn'ün SVM sınıflarında, C hiperparametresi kullanılarak bu denge kontrol edilebilmektedir. Aşağıdaki görselde de görebileceğiniz gibi C ne kadar büyükse Marjin o kadar dar olacaktır.

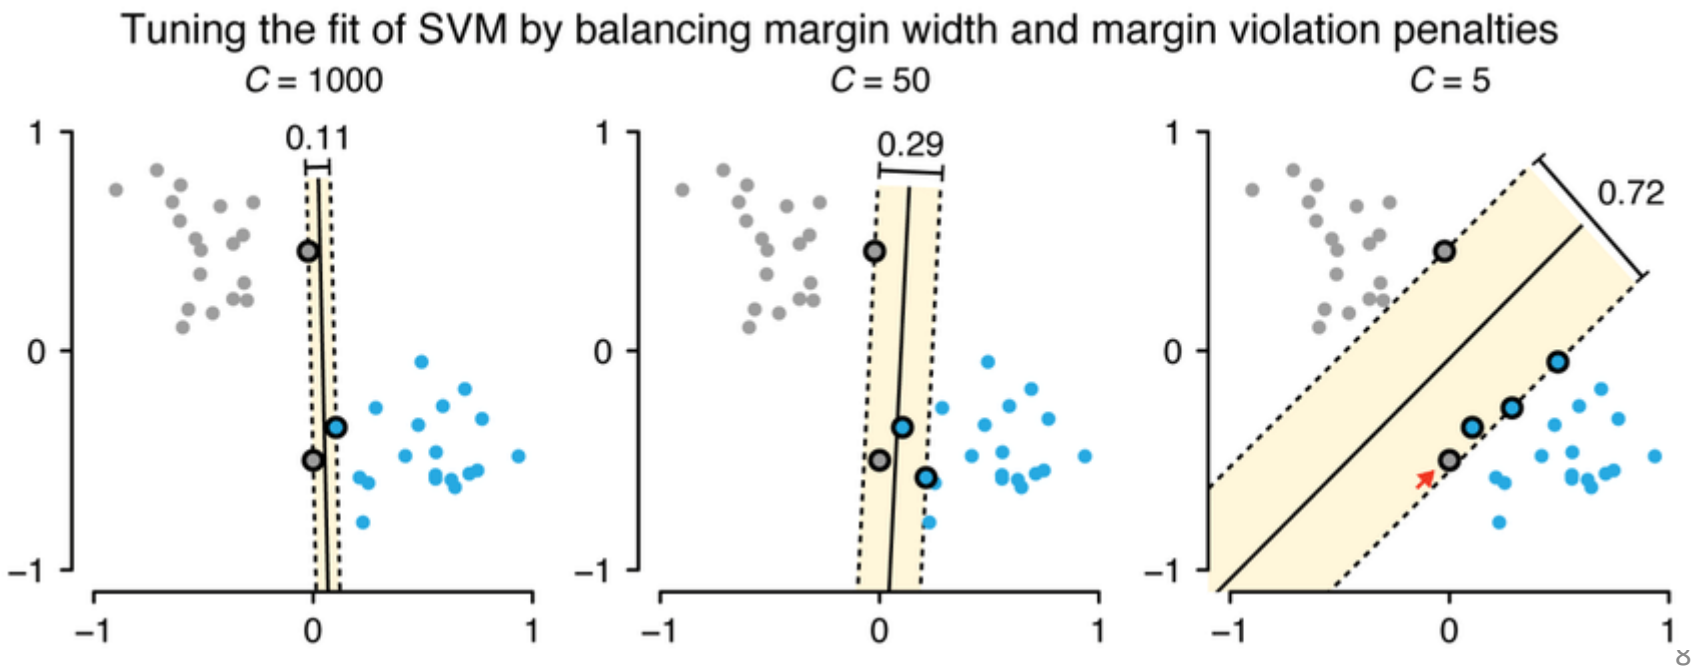

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

•**Destek Vektör Makineleri'nde (SVM) bir veri noktası hiper düzlem ile marjin sınırı arasına düşerse, sonuç kullandığınız SVM türüne göre değişir:**

◆ Hard Margin SVM (Katı Marjin)

- Bu duruma **izin verilmez**. Tüm veri noktaları marjinin dışında olmalıdır.
- Eğer böyle bir nokta varsa model **çözüm bulamaz** (infeasible).
- Zaten bu yüzden pratikte pek kullanılmaz.

◆ Soft Margin SVM (Esnek Marjin) – Pratikte Kullanılan

Bu durumda devreye **slack variable (gevşeklik değişkeni) ξ (ksi)** girer:

- Noktanın marjin ihlali miktarı ξ ile ölçülür.
- **0 < ξ < 1** → Nokta marjin içinde ama **doğru sınıfta**. Yani sınıflandırma doğru yapılır ama marjin ihlal edilmiş olur.
- **ξ = 1** → Nokta tam hiper düzlem üzerinde.
- **ξ > 1** → Nokta **yanlış sınıfta** (misclassification).

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

•**Destek Vektör Makineleri'nde (SVM) bir veri noktası hiper düzlem ile marjin sınırı arasına düşerse, sonuç kullandığınız SVM türüne göre değişir:**

Durum	ξ Değeri	Sonuç
Marjin dışında (doğru taraf)	$\xi = 0$	✅ İdeal durum
Marjin içinde (doğru taraf)	**$0 < \xi < 1$**	⚠️ **Doğru sınıf ama marjin ihlali**
Hiper düzlem üzerinde	$\xi = 1$	❌ Belirsiz
Yanlış tarafta	$\xi > 1$	❌ Yanlış sınıflandırma

C parametresi bu ihlallere ne kadar tolerans gösterileceğini kontrol eder:

- **C büyük** → İhlallere az tolerans, dar marjin
- **C küçük** → İhlallere fazla tolerans, geniş marjin

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

•Destek Vektör Makineleri'nde (SVM) bir veri noktası hiper düzlem ile marjin sınırı arasına düşerse, sonuç kullandığınız SVM türüne göre değişir:

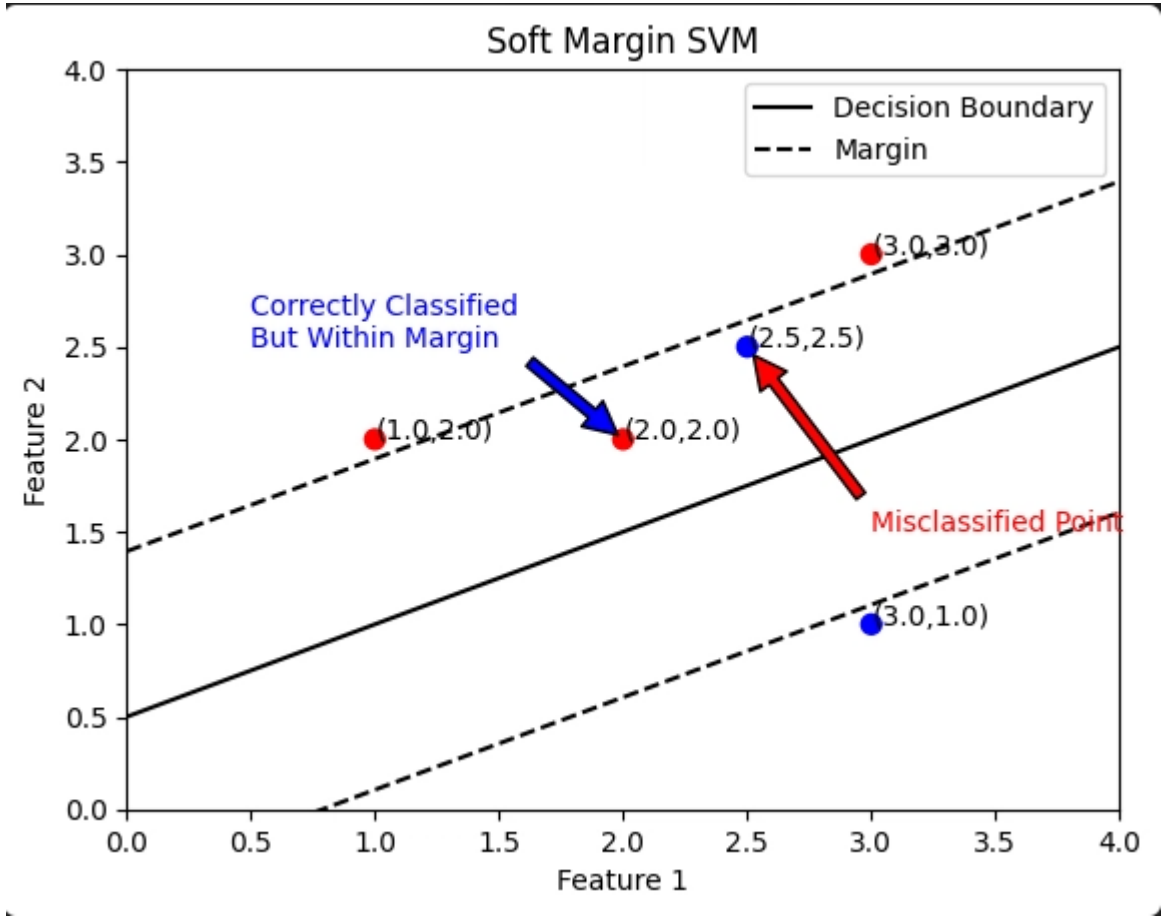

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Gerçek Dünya - Soft Margin ve C Parametresi:

Gerçek hayattaki veriler her zaman kusursuz bir çizgiyle ikiye ayrılamaz (Linearly Inseparable). Araya karışmış aykırı değerler (outliers) olabilir. Bu durumda algoritmanın hata yapmasına bir miktar izin vermeliyiz. Buna **Soft Margin (Yumuşak Marj)** denir.

C Parametresi (Düzenlileştirme - Regularization):

- **C değeri küçükse:** Model hatalara toleranslıdır. Marj genişler, genel eğilim yakalanır ancak eğitim verisinde daha çok hata yapılabilir (Underfitting'e meyil).
- **C değeri büyükse:** Model hiç hata yapmak istemez. Marj daralır, her noktayı doğru sınıflandırmaya çalışır ancak yeni verilerde başarısız olabilir (Overfitting'e meyil).

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Doğrusal Olmayan Destek Vektör Makineleri

Doğrusal olmayan veri kümelerinde SVM'ler doğrusal bir hiper-düzlem çizemeyeceği için çekirdek numaraları (kernel tricks) kullanılmaktadır.

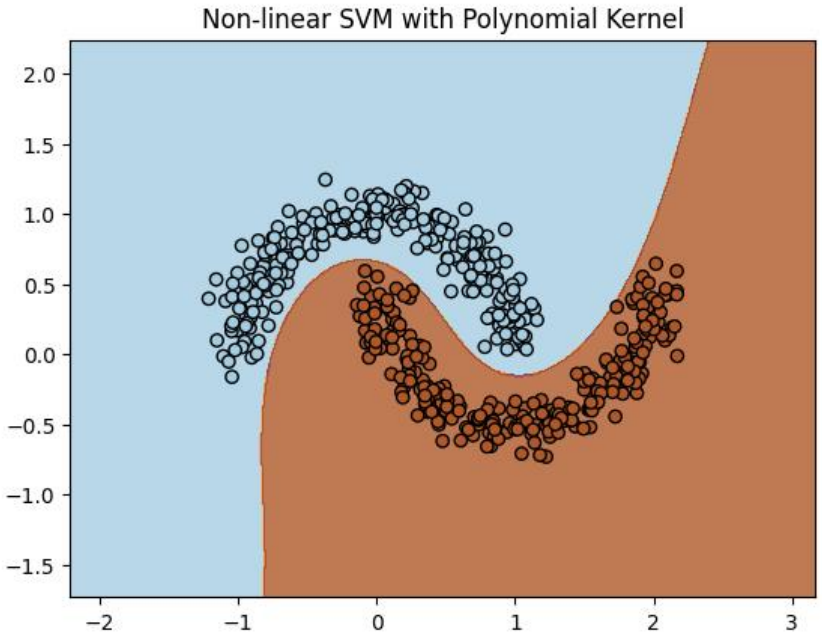

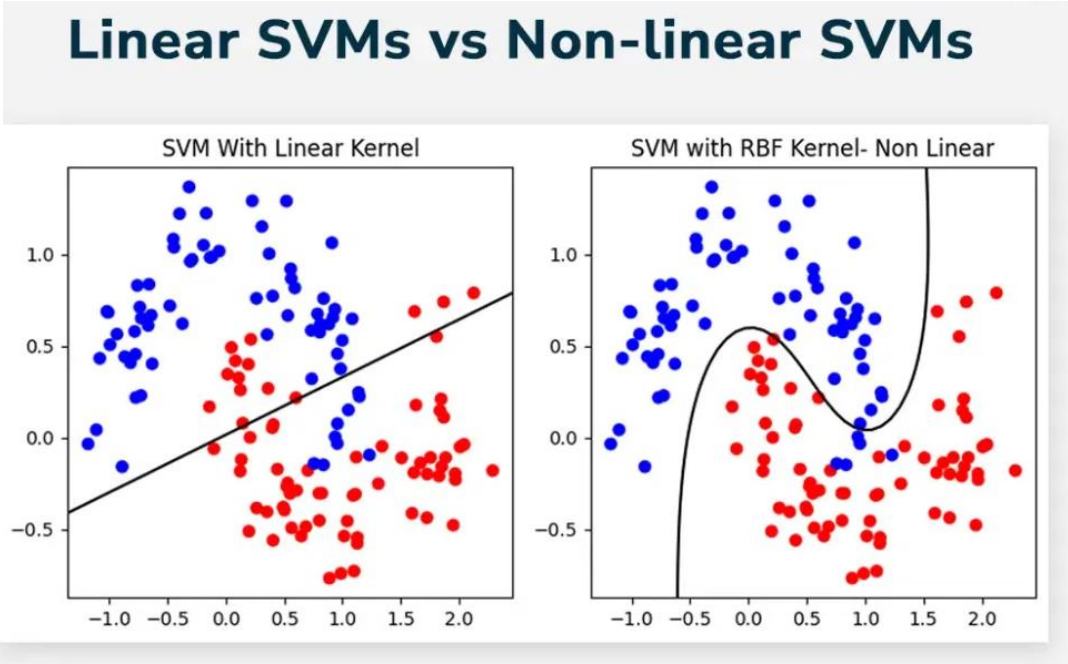

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Doğrusal Olmayan Destek Vektör Makineleri

Örneğin, elma ve portakal gibi meyveleri renk ve doku gibi özelliklere göre sınıflandırmayı düşünün. Elma veri noktaları, portakallarla çevrili dairesel bir küme oluşturabilir. Basit bir SVM bunları ayıramaz, ancak doğrusal olmayan bir SVM, kavisli sınırlar oluşturmak için çekirdek fonksiyonları kullanarak bunu halleder ve bu tür karmaşık, doğrusal olmayan desenleri doğru bir şekilde sınıflandırmasına olanak tanır.

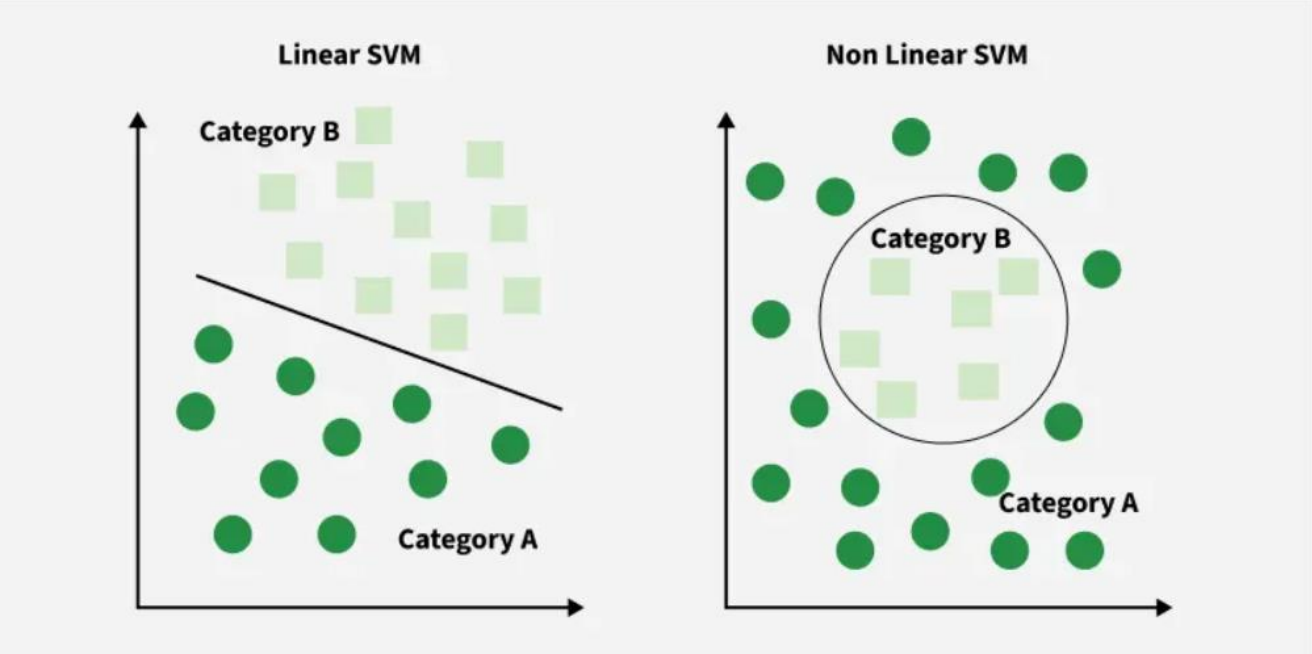

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Doğrusal Olmayan Destek Vektör Makineleri

Eğer veri 2 boyutta bir doğru ile hiçbir şekilde ayrılamayacak kadar iç içe geçmişse ne yaparız? SVM, veriyi daha yüksek bir boyuta (örneğin 3 boyuta) taşıyarak orada bir düzlemle ayırmayı dener.

Ancak bu boyut dönüştürme işlemi matematiksel olarak çok ağır bir işlemdir. İşte **Kernel Trick**, veriyi gerçekten yüksek boyuta taşımadan, yüksek boyuttaki iç çarpımlarını (dot product) hesaplayabilen mucizevi matematiksel bir kısayoldur.

- **Linear Kernel:** Veri doğrusal olarak ayrılabiliyorsa kullanılır. (Temel model)
- **Polynomial Kernel:** Veriyi polinomiyal eğrilerle ayırır.
- **RBF (Radial Basis Function) Kernel:** En popüler olanıdır. Uzaklıklara dayalı, dairesel/karmaşık sınırları çizebilir. Sonsuz boyutlu bir uzayda işlem yapar gibi davranır.

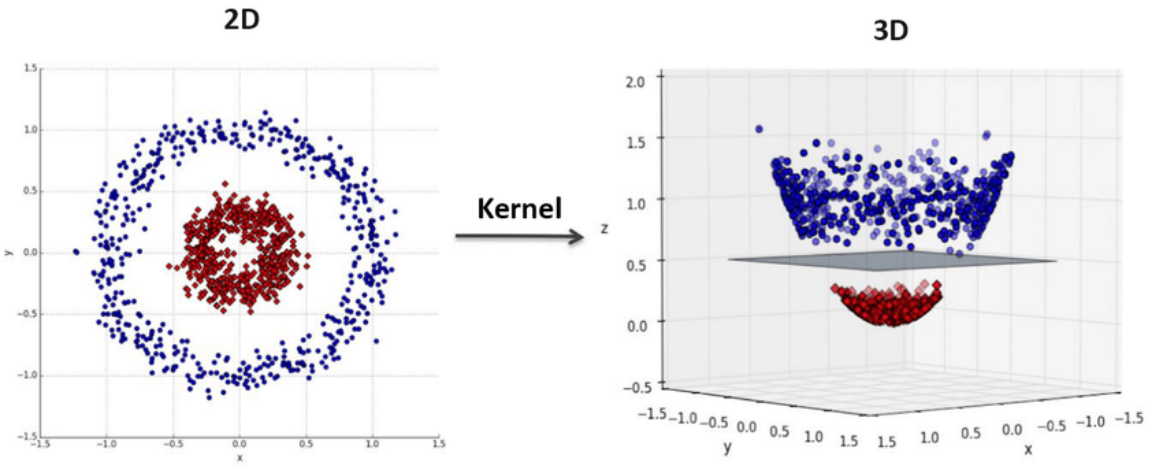

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Doğrusal Olmayan Destek Vektör Makineleri

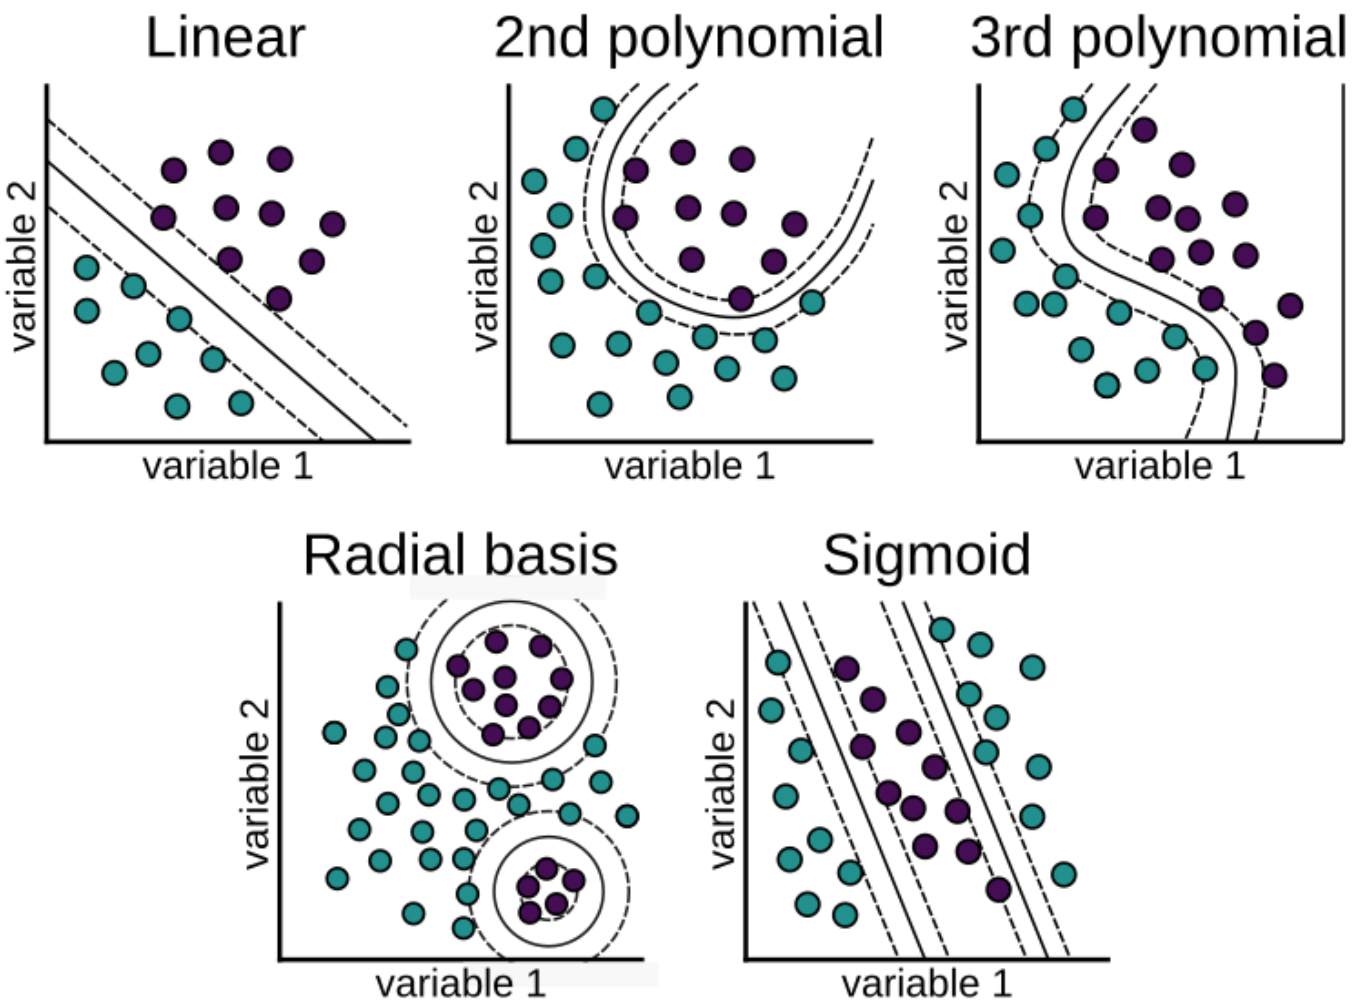

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Breast cancer data seti örnek deney çalışması:

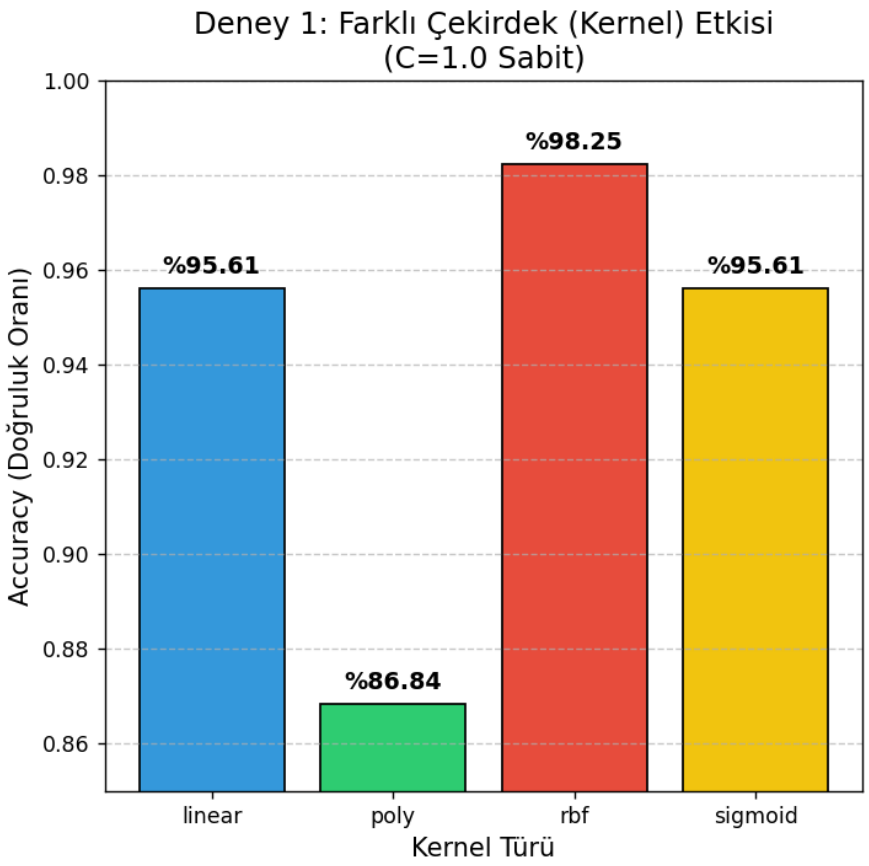

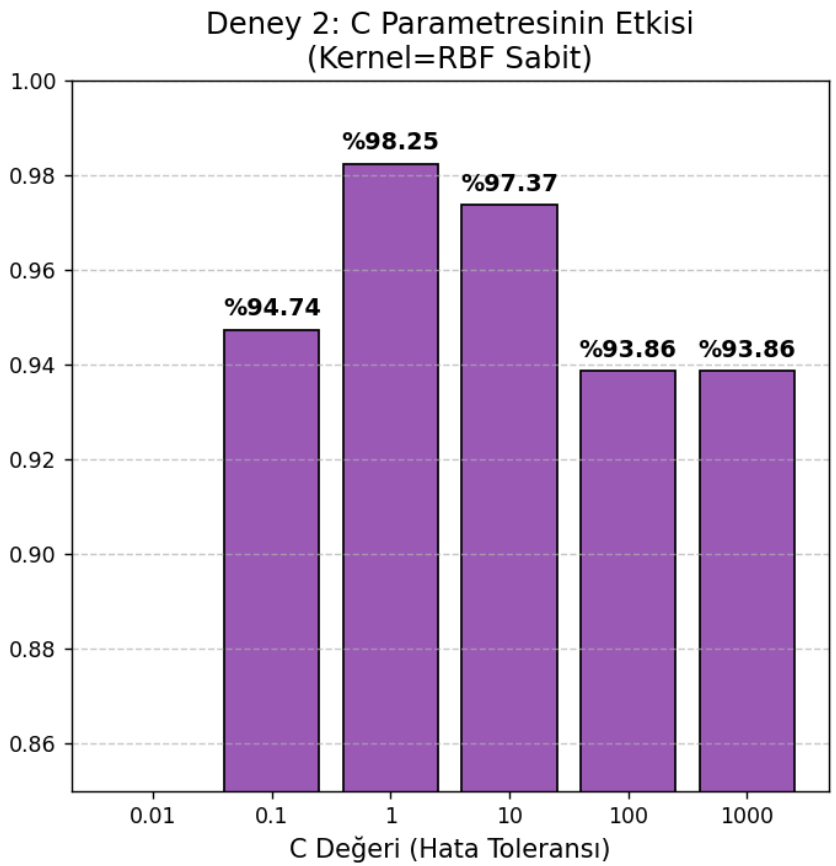

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Multi-Class classification problem with SVM:

Destek Vektör Makineleri (SVM), doğası gereği ve matematiksel olarak sadece ikili (binary) bir sınıflandırıcıdır. Yani algoritmanın temeli sadece iki grubu birbirinden ayıran tek bir çizgi/düzlem çekmeye dayanır.

Peki elimizde 3 veya daha fazla sınıf (örneğin: Kedi, Köpek, Kuş) varsa ne yapar? Matematiği baştan yazmak yerine, bu çok sınıflı problemi küçük ikili problemlere böler.Bunu yapmak için endüstride kullanılan iki temel strateji vardır:

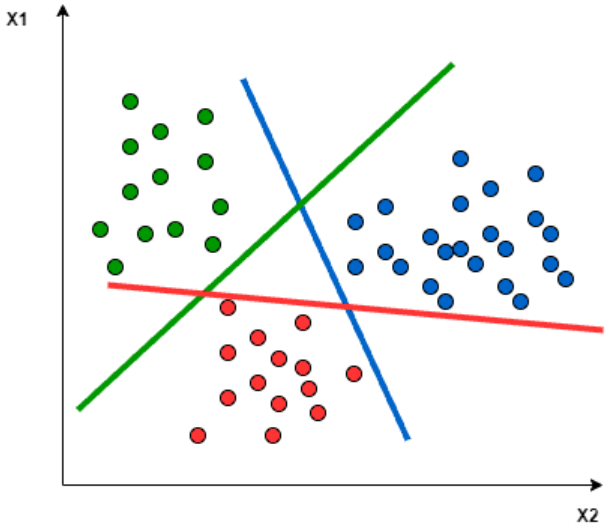

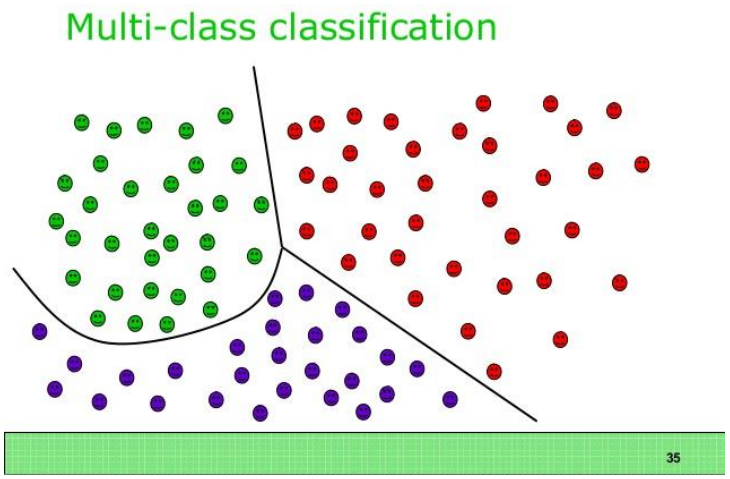

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Multi-Class classification problem with SVM:

1. One-vs-Rest (OvR) / Bire Karşı Diğerleri (En Yaygın Yöntem)

- Çoğu kütüphane (Scikit-Learn dahil) varsayılan olarak bu mantığı kullanır.
- Elimizde 3 sınıf (A, B ve C) olduğunu varsayalım. Algoritma arka planda 3 farklı hiperdüzlem (model) oluşturur:
  - 1. Hiperdüzlem: A Sınıfı mı? YOKSA (B veya C) mi?
  - 2. Hiperdüzlem: B Sınıfı mı? YOKSA (A veya C) mi?
  - 3. Hiperdüzlem: C Sınıfı mı? YOKSA (A veya B) mi?

Karar Aşaması: Yeni bir veri noktası geldiğinde, bu 3 modele birden sorulur. Her model bir güven skoru (noktanın hiperdüzleme olan pozitif uzaklığı) üretir. Hangi model en yüksek, en emin skoru üretirse, veri o sınıfa atanır.

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Multi-Class classification problem with SVM:

2. One-vs-One (OvO) / Bire Karşı Bir

Elimizde 3 sınıf (A, B ve C) olduğunu varsayalım. Bu yöntemde, her sınıf çifti kendi arasında yarışır.

- A ile B'yi ayıran bir çizgi,
- A ile C'yi ayıran bir çizgi,
- B ile C'yi ayıran bir çizgi çizilir.

Eğer N tane sınıfımız varsa, sistem toplamda N(N-1)/2 adet küçük SVM modeli eğitir. Yeni bir veri geldiğinde tüm modeller birbiriyle maç yapar ve en çok "oy" alan sınıf kazanır.

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Multi-Class classification problem with SVM: Breast cancer dataset

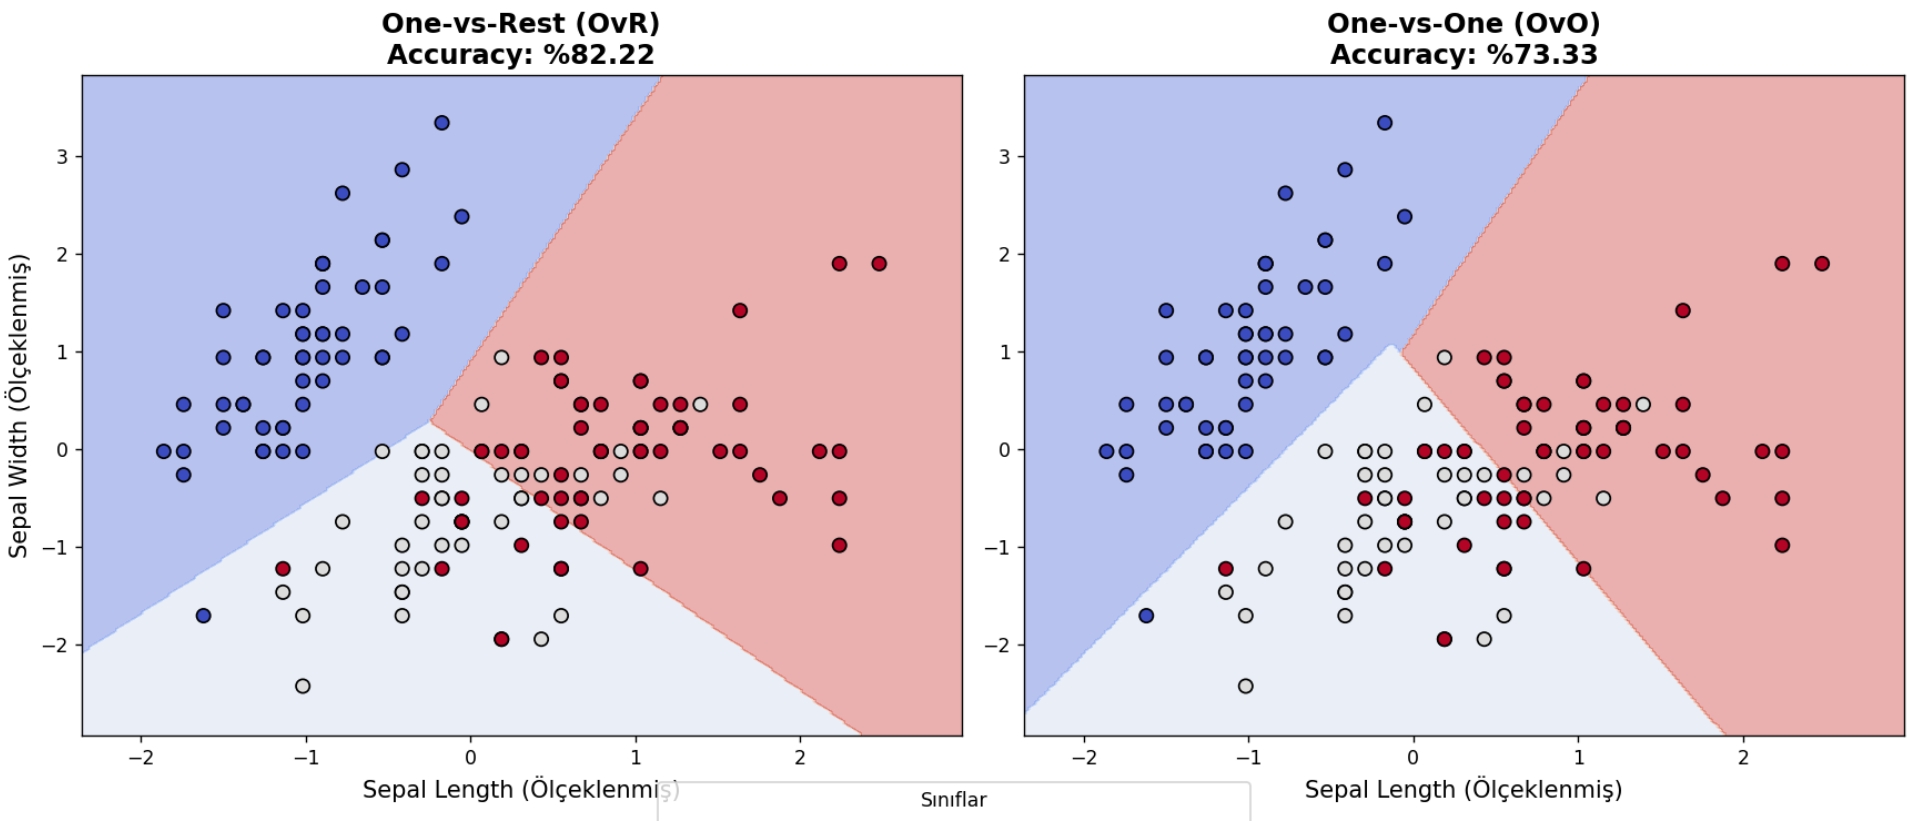

Denetimli(Gözetimli-Supervised) Öğrenme
Destek vektör makineleri-support vector machines-SVM

Multi-Class classification problem with SVM: wine dataset

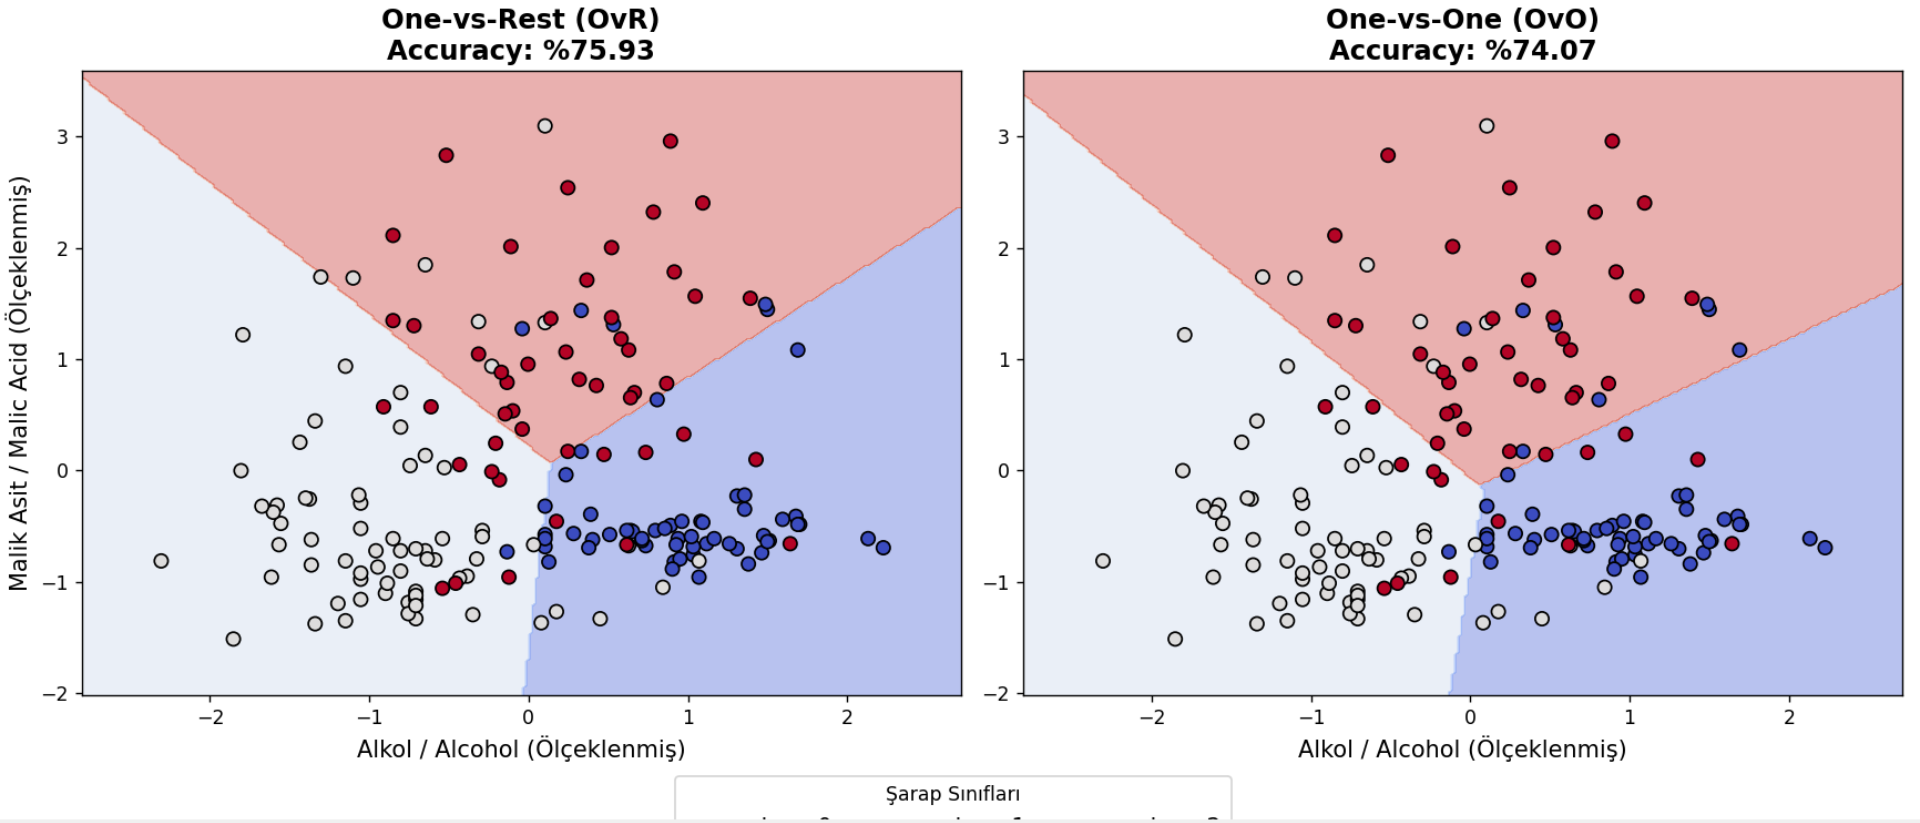

- Haftaya: Karar Ağaçları, Rastgele Ormanlar, K-means, makine öğrenmesi değerlendirme metrikleri

- Doç. Dr. Musa AYDIN
- musa.aydin@samsun.edu.tr

Ofis No: 419