Yapay Zeka ve Veri Mühendisliği Bölümü

YZVM102 Veri Bilimine Giriş
2025-2026 Bahar Yarıyılı

Hafta 9 – Karar Ağaçları (Decision Trees)
Rastgele Ormanlar (Random Forest)

Doç. Dr. Musa AYDIN

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees)

- **Karar ağacı (decision tree):** Karar ağaçları (Decision Tree) algoritması, supervised learningde (denetimli öğrenmede), tree based (ağaç bazlı) öğrenme algoritmalarından birisidir. Hem sınıflandırma (classification) hem de regresyon için kullanılabilmektedir,
- Karar ağaçları, ağaç yapısı şeklindeki bir dizi karar kuralıyla veri kümesini bölerek, hedef değişkenin tahmin edilmesini sağlar.

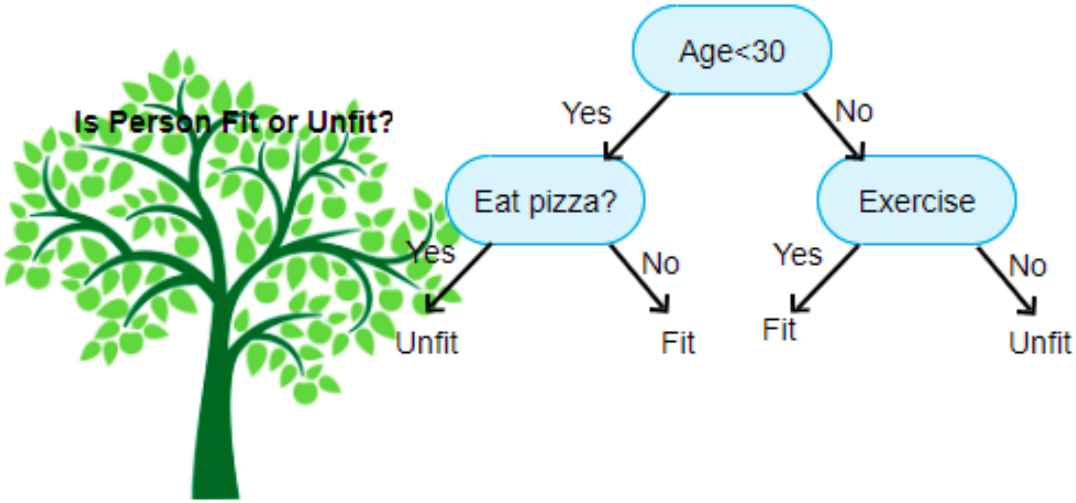

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees)

- **Karar ağacı (decision tree):** Ağaç yapısında ilk bölünmenin başladığı yere, **kök, dalların uzaması ile gelişen kısımlara düğümler,** ve en son kararın verildiği alt uçlarına ise **yapraklar deniliyor (bölünmenin sonlandığı node lar).**
- Kök hücrelerinin altında düğümler (interval nodes veya nodes) bulunur. Her bir gözlem düğümler yardımıyla sınıflandırılır. Düğüm sayısı arttıkça modelin karmaşıklığı da artar.

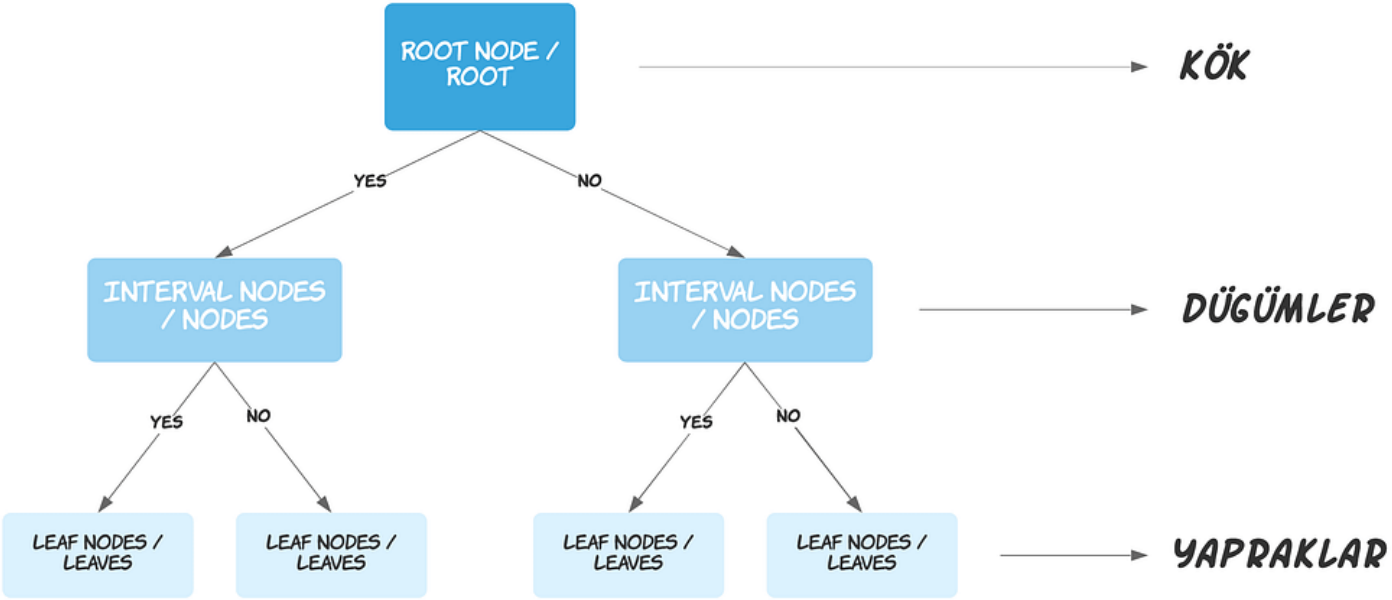

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees)

- **Karar ağacı (decision tree):** Kök hücrelerinin altında düğümler (interval nodes veya nodes) bulunur. Her bir gözlem düğümler yardımıyla sınıflandırılır. Düğüm sayısı arttıkça modelin karmaşıklığı da artar.
- Node larda yazan feature lar nasıl seçiliyo (age, smoker, weight, vb.) veya root neden smoker olmadı age oldu ?

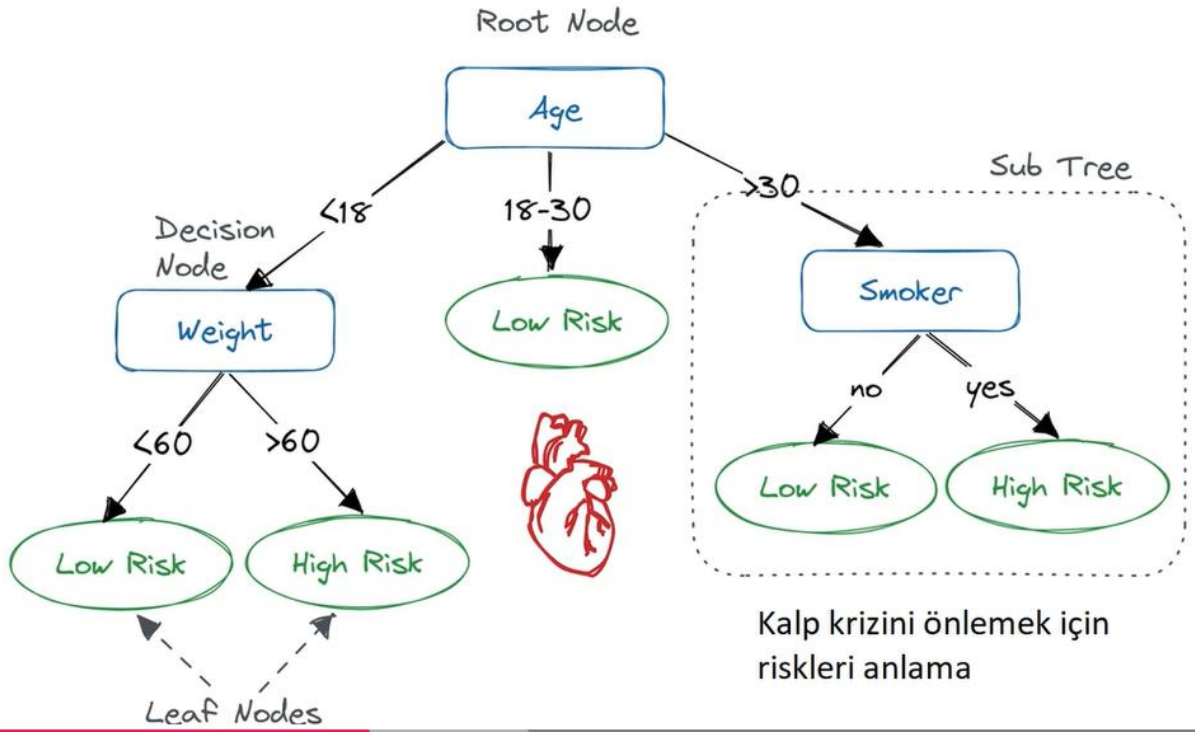

Kalp krizini önlemek için riskleri anlama

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees)

- Karar ağacı (decision tree): **örnek: 4 feature 1 etiket (yes/no)**

Karar Ağaçları

Outlook	Temperature	Humidity	Wind	Played football(yes/no)
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

4

etiket

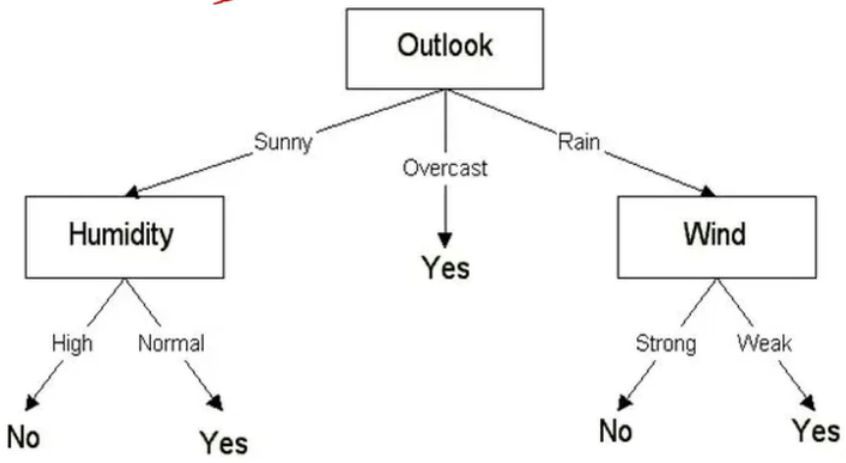

troined

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** karar ağaçlarını oluşturmak için kullanılan en klasik algoritmalardan biridir. Temel amacı, veri setini en az soruyla en doğru şekilde sınıflandırmaktır.
- Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Karar Ağaçları Türleri

	ID3	**C4.5**	**CART**
Veri Tipi	Kategorik	Sürekli ve Kategorik	Sürekli ve Kategorik
Veri Boyutu	Orta ve Küçük Veri Setleri	Orta ve Büyük Veri Setleri	Büyük Veri Setleri
Hız	Düşük	Orta	Yüksek
Boosting	Yok	Yok	Var (Rastgele Ormanlar, Gradient Boosting)
Kayıp Veri	Hassas	Orta Düzeyde Hassas	Yüksek (Kayıp verinin üstesinden gelebilir)
Algoritma	Entropi ve Bilgi Kazancı	Bölme Bilgisi ve Kazanç Oranı	Gini Impurity

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** karar ağaçlarını oluşturmak için kullanılan en klasik algoritmalardan biridir. Temel amacı, veri setini en az soruyla en doğru şekilde sınıflandırmaktır.
- Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

ID3

Herhangi bir feature kaldı mı ?
Yaprak düşüme ulaştın mı ?

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** karar ağaçlarını oluşturmak için kullanılan en klasik algoritmalardan biridir. Temel amacı, veri setini en az soruyla en doğru şekilde sınıflandırmaktır.
- Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Bilgi Kazancı (Information Gain)

- Bir özelliğin bölünme noktasının ne kadar iyi olduğunu belirlemek için kullanılır.
- Özü, bir özelliğin seçilmesinin, veri kümesinin ne kadar iyi sınıflandırılacağına dair belirsizliği azaltıp azaltmadığını ölçmektir.
- Yani, bir özellik seçildiğinde, yeni oluşan alt kümelerin daha homojen olup olmadığını değerlendirir.
- Bilgi kazancı ne kadar yüksekse, bir özellik o kadar iyi bir bölünme kriteri olarak kabul edilir.

$$Gain(S,A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

S = tüm veri seti, A = feature lar

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

= karışıklık (karmaşık) olarak düşünülebilir

Entropi düşükse, homojenlik yüksektir, Entropi yüksekse heterojenlik yüksektir.

Entropi

- Karar ağaçları (decision trees) içinde entropi, belirli bir düğümdeki veri noktalarının sınıflarının ne kadar karışık olduğunu ölçen bir metriktir.

- Daha düşük bir entropi değeri, bir düğümün daha homojen sınıflara sahip olduğunu, yani veri noktalarının çoğunluğunun aynı sınıfa ait olduğunu gösterir
- Daha yüksek bir entropi değeri ise, bir düğümün daha karışık sınıflara sahip olduğunu, yani veri noktalarının farklı sınıflara daha eşit olarak dağıldığını gösterir.

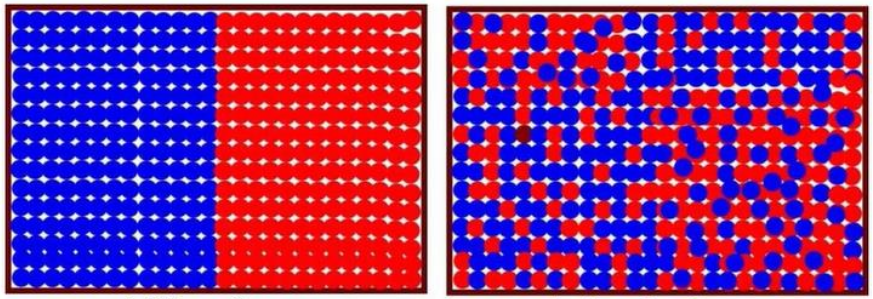

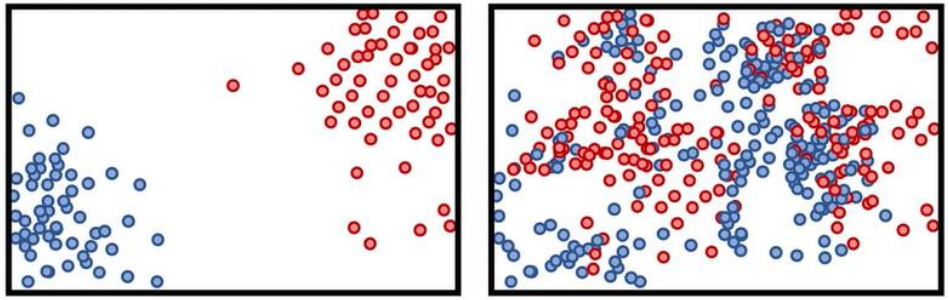

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Entropi: Bir veri grubundaki "belirsizliği" veya "karışıklığı" ölçer. Eğer bir gruptaki herkes "Grip" ise belirsizlik (entropi) sıfırdır. Ama grubun yarısı "Grip" yarısı "Sağlıklı" ise belirsizlik en yüksek seviyededir.

Entropi

$$E(S) = \sum_{i=1}^{c} -p_i \log_2 p_i$$

Play Golf	
Yes	No
9	5

p1 p2

$\frac{9}{14}$ $\frac{5}{14}$

yes No

Entropy(PlayGolf) = Entropy (5,9)
= Entropy (0.36, 0.64)
= - (0.36 $\log_2$ 0.36) - (0.64 $\log_2$ 0.64)
= 0.94

No yes

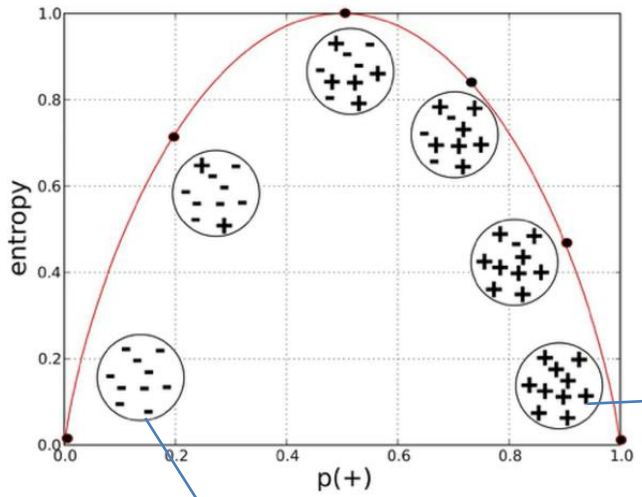

Tamamı pozitif ise ent. 0

Tamamı neg. İse entropi 0

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Outlook	Temperature	Humidity	Wind	Played football(yes/no)
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Entropy: rastgeleliğe, belirsizliği ve beklenmeyen durumun ortaya çıkma olasılığını gösterir. Eğer örnekler tamamı düzenli / homojen ise entropisi sıfır olur. Eğer değerler birbirine eşit ise entropi 1 olur. Örneğin Futbol Oyna hepsi "Evet" veya "Hayır" olsa entropi sıfır olurdu. Entropi formülasyonu:

$$E(S) = \sum_{i=1}^{c} - p_i \log_2 p_i$$

Futbol Oyna	
Evet	**Hayır**
9	5

E(FutbolOyna)=***E***(FutbolOyna=Evet)+***E***(FutbolOyna=Hayır)

Evet için olasılık değeri p1 = 9/14=0.643

Hayır için olasılık değeri p2 = 5/14 = 0.357

***E*(FutbolOyna)** = 0.940

Entropi sadece hedef üzerine hesaplanmaz. Ayrıca özellikler üzerine entropi hesaplanabilir. Fakat özellikler üzerine entropi hesaplanırken hedefte göz önüne alır. Bu durumda entropi formülü:

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

$$E(T,X)=\sum_{c\in X}P(c)E(c)$$

		Futbol Oyna		
		Evet	Hayır	Toplam
Hava Durumu	Güneşli	3	2	5
	Bulutlu	4	0	4
	Yağmurlu	2	3	5
				14

E(FutbolOyna, HavaDurumu) = **P**(Güneşli)***E**(3,2)+**P**(Bulutlu)***E**(4,0)+**P**(Yağmurlu)***E**(2,3)

P(Güneşli) = 5/14 = 0.3571, **E**(3,2) = 0.971

P(Bulutlu)= 4 / 14 = 0.286, **E**(4,0) = 0

P(Yağmurlu)= 5 / 14 = 0.357, **E**(2,3) = 0.971

E(FutbolOyna, HavaDurumu) = 0.694

		Futbol Oyna		
		Evet	Hayır	Toplam
Nem	Yüksek	3	4	7
	Normal	6	1	7
				14

E(FutbolOyna, Nem) = **P**(Yüksek)***E**(3,4)+**P**(Normal)***E**(6,1)

E(3,4) = 0.985, **P**(Yüksek) = 0.5

E(6,1) = 0.592, **P**(Normal) = 0.5

E(FutbolOyna, Nem) = 0.788

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

		Futbol Oyna		
		Evet	Hayır	Topla
Sıcaklık	Sıcak	2	2	4
	Ilık	4	2	6
	Soğuk	3	1	4
				14

E(FutbolOyna, Sıcaklık) = **P**(Sıcak)***E**(2,2) + **P**(Ilık)***E**(4,2) + **P**(Soğuk)***E**(3,1)

E(3,2) = 1.000, **P**(Güneşli) = 0.286

E(4,0) = 0.918, **P**(Bulutlu) = 0.429

E(2,3) = 0.811, **P**(Yağmurlu) = 0.286

E(FutbolOyna, Sıcaklık) = 0.911

		Futbol Oyna		
		Evet	Hayır	Toplam
Rüzgar	Yok	6	2	8
	Var	3	3	6
				14

E(FutbolOyna, Rüzgar) = **P**(Yok)***E**(6,2)+**P**(Var)***E**(3,3)

E(3,4) = 0.811, **P**(Yüksek) = 0.571

E(6,1) = 1.000, **P**(Normal) = 0.429

E(FutbolOyna, Rüzgar) = 0.892

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Information Gain (Bilgi Kazanımı)

Bilgi kazanımı, bir veri setini bir özellik üzerinde böldükten (Örneğin **E**(FutbolOyna, HavaDurumu)) sonra tüm entropiden (**E**(FutbolOyna)) çıkarmaya dayanır. Entropinin küçük değer içermesi durumunda özelliğin önemi Decision Tree algoritması ID3 için artmaktadır. Diğer taraftan 1'e yaklaştıkça özelliğinin önemi azalır. Ancak information gain'de olay tam tersidir ve bu açıdan entropinin tersi gibi düşünülebilir. Decision Tree inşa edilirken en yüksek değerleri information gain'e sahip özellik seçilir.

$$Gain(T,X) = Entropy(T) - Entropy(T,X)$$

Gain(FutbolOyna, HavaDurumu) = **E**(FutbolOyna) – **E**(FutbolOyna, HavaDurumu)

Gain(FutbolOyna, HavaDurumu) = 0.940 – 0.694 = 0.247 *

Gain(FutbolOyna, Nem) = 0.940 – 0.788 = 0.152

Gain(FutbolOyna, Sıcaklık) = 0.940 – 0.911 = 0.029

Gain(FutbolOyna, HavaDurumu) = 0.940 – 0.892 = 0.048

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Gain(FutbolOyna, HavaDurumu) özelliği en yüksek information gain değerine sahiptir. Bu özellik seçildikten sonra özelliğin değerlerine bakılarak en yüksek information gain'e sahip alan seçilir. HavaDurumu Bulutlu olduğunda tüm FutbolOyna değerleri Evet'tir. Şekil olarak aşağıdaki gibidir:

Özellikler				Hedef
Hava Durumu	Sıcaklık	Nem	Rüzgar	Futbol Oyna
Bulutlu	Sıcak	Yüksek	Yok	Evet
Bulutlu	Soğuk	Normal	Var	Evet
Bulutlu	Ilık	Yüksek	Var	Evet
Bulutlu	Sıcak	Normal	Yok	Evet

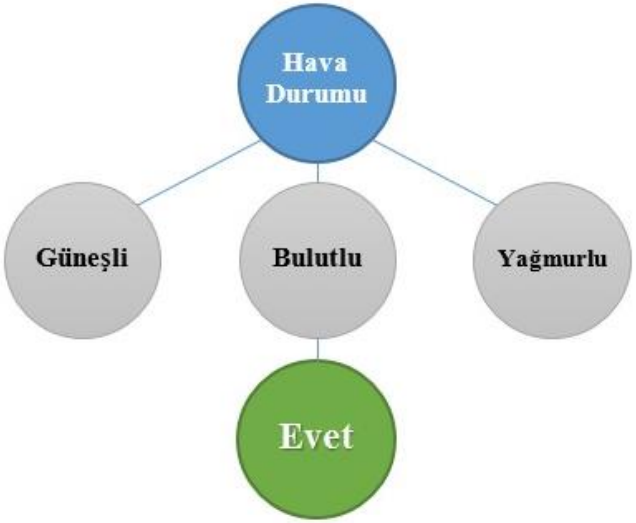

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Gain(FutbolOyna, HavaDurumu) özelliği en yüksek information gain değerine sahiptir. Bu özellik seçildikten sonra özelliğin değerlerine bakılarak en yüksek information gain'e sahip alan seçilir. HavaDurumu Bulutlu olduğunda tüm FutbolOyna değerleri Evet'tir. Şekil olarak aşağıdaki gibidir:

Özellikler				Hedef
Hava Durumu	Sıcaklık	Nem	Rüzgar	Futbol Oyna
Bulutlu	Sıcak	Yüksek	Yok	Evet
Bulutlu	Soğuk	Normal	Var	Evet
Bulutlu	Ilık	Yüksek	Var	Evet
Bulutlu	Sıcak	Normal	Yok	Evet

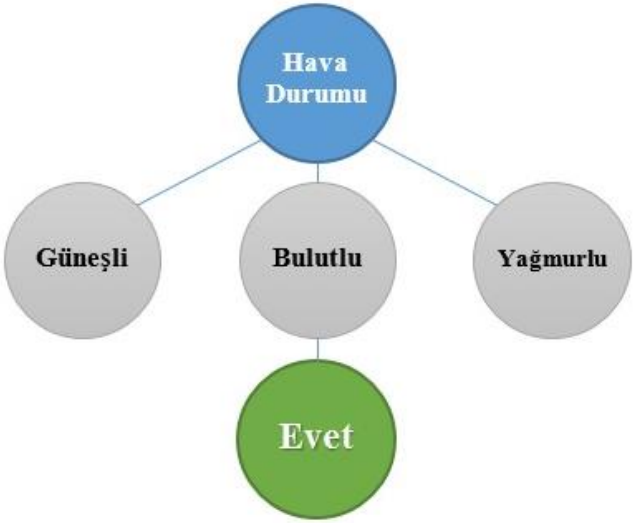

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **ID3 (Iterative Dichotomiser),** Algoritma Aday Bölünmeleri değerlendirmek için entropi ve bilgi kazancını kullanır.

Karar Ağaçları

Outlook	Temperature	Humidity	Wind	Played football(yes/no)
Sunny	Hot	High	Weak	No
Sunny	Hot	High	Strong	No
Overcast	Hot	High	Weak	Yes
Rain	Mild	High	Weak	Yes
Rain	Cool	Normal	Weak	Yes
Rain	Cool	Normal	Strong	No
Overcast	Cool	Normal	Strong	Yes
Sunny	Mild	High	Weak	No
Sunny	Cool	Normal	Weak	Yes
Rain	Mild	Normal	Weak	Yes
Sunny	Mild	Normal	Strong	Yes
Overcast	Mild	High	Strong	Yes
Overcast	Hot	Normal	Weak	Yes
Rain	Mild	High	Strong	No

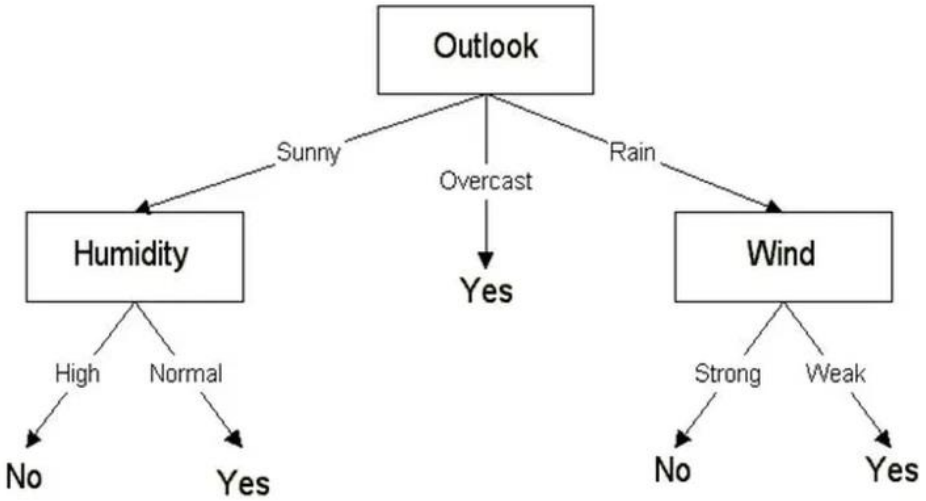

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree):** CART (Classification and Regression Tree) algoritmasının ID3'ten en büyük farkı her zaman ikili (binary) bölünme yapması ve Entropi yerine Gini Safsızlığı (Gini Impurity) kullanmasıdır.
- **Gini'nin amacı basittir:** Bir torbadan rastgele iki top çektiğimizde, bunların farklı renkte olma ihtimali nedir? İhtimal düşükse torba "saf" (Gini 0'a yakın), ihtimal yüksekse torba "karışık" demektir.

CART

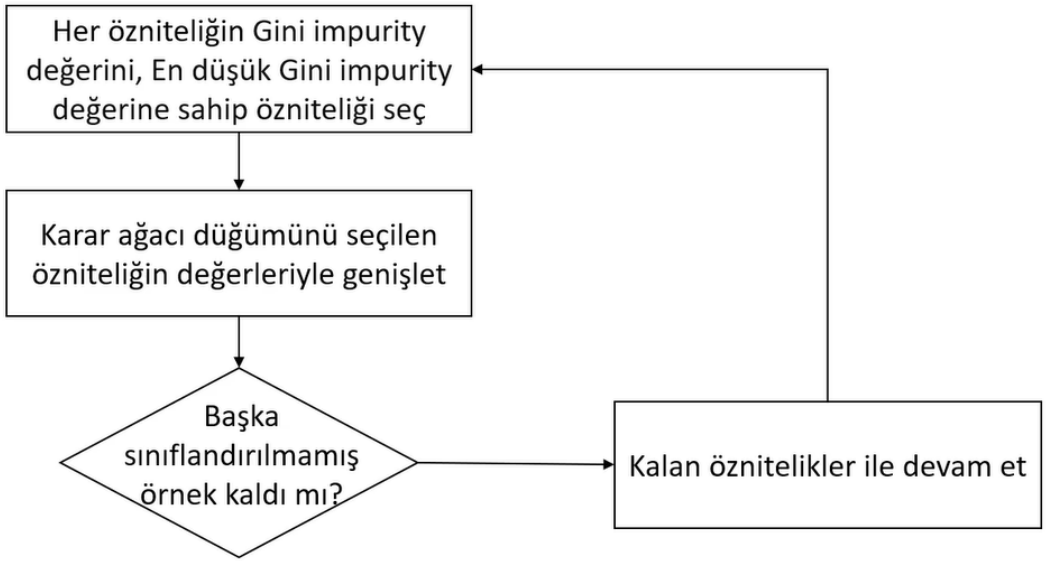

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree):** CART (Classification and Regression Tree) algoritmasının ID3'ten en büyük farkı her zaman ikili (binary) bölünme yapması ve Entropi yerine Gini Safsızlığı (Gini Impurity) kullanmasıdır.
- **Gini'nin amacı basittir:** Bir torbadan rastgele iki top çektiğimizde, bunların farklı renkte olma ihtimali nedir? İhtimal düşükse torba "saf" (Gini 0'a yakın), ihtimal yüksekse torba "karışık" demektir.

CART

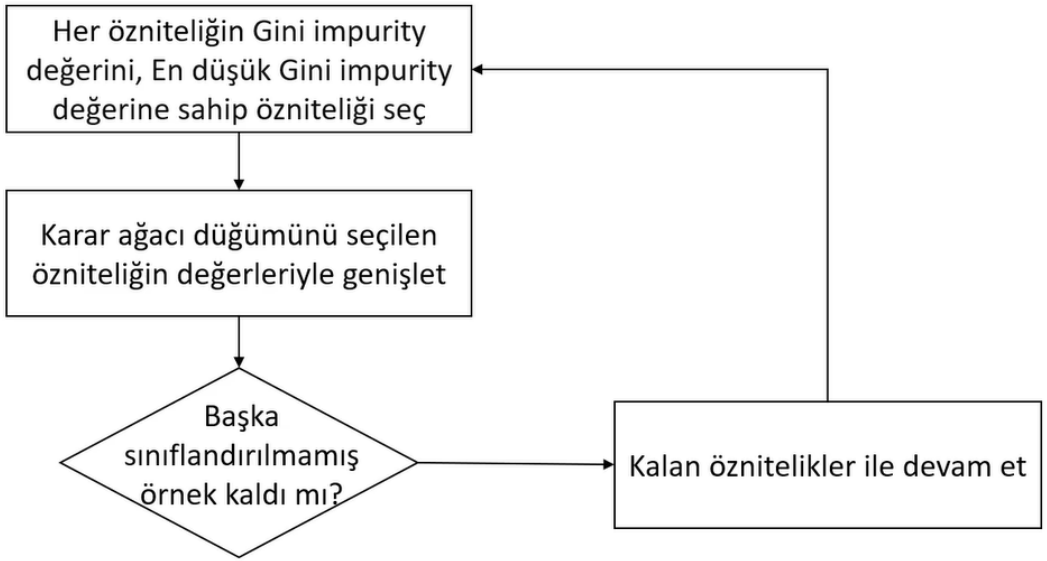

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree):**
- **Gini Impurity:** Bir düğümdeki veri noktalarının farklı sınıflara dağılımının ne kadar karışık olduğunu ölçer.
- Gini karışıklığı, 0 ile 0.5 arasında bir değer alır, 0 en saf durumu (yani tüm veri noktalarının aynı sınıfa ait olduğu durumu), 0.5 ise en karışık durumu ifade eder.
- Bir düğümün Gini karışıklığı ne kadar düşükse, o kadar homojen sınıflara sahip olur ve böylece daha iyi bir bölünme kriteri olarak kabul edilir.

$$Gini\ Impurity = 1 - \sum p_i^2$$

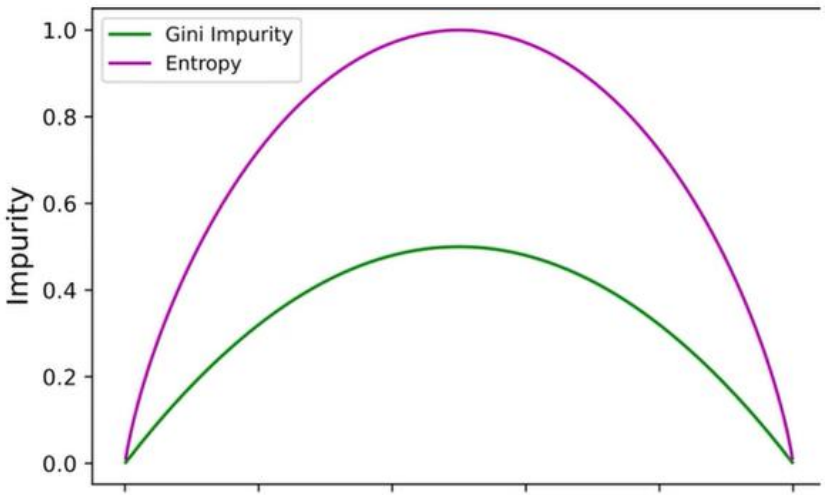

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree):**
- **Örnek durum çalışması: Senaryo: Tenis Oynanacak mı?**

Elimizde 14 günlük bir geçmiş veri seti var. Hedefimiz (label), rüzgar durumuna bakarak tenis oynanıp oynanmayacağını tahmin etmek.

Adım 1: Kök Düğümün (Başlangıç) Gini Değerini Hesaplama

Veri setinin genel dağılımı: 14 Gün (9 Evet / 5 Hayır)

- p(Evet) = 9/14 ≈ 0.643
- p(Hayır) = 5/14 ≈ 0.357

Gini (Başlangıç) = $1 - [(9/14)^2 + (5/14)^2] = 1 - [0.413 + 0.127] =$ **0.460**

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree): Örnek durum çalışması: Senaryo: Tenis Oynanacak mı?**

Elimizde 14 günlük bir geçmiş veri seti var. Hedefimiz (label), rüzgar durumuna bakarak tenis oynanıp oynanmayacağını tahmin etmek.

Adım 2: Veriyi "Rüzgar" Özelliğine Göre Bölme

Rüzgarın iki durumu var: Zayıf ve Güçlü. Veri şu şekilde ayrılıyor:

Grup	Veri Sayısı	Evet / Hayır	Gini Hesabı
Rüzgar = Zayıf	8 Gün	6 Evet / 2 Hayır	$1 - [(6/8)^2 + (2/8)^2] =$ **0.375**
Rüzgar = Güçlü	6 Gün	3 Evet / 3 Hayır	$1 - [(3/6)^2 + (3/6)^2] =$ **0.500**

Adım 3: Ağırlıklı Gini (Weighted Gini) Hesaplaması

Bölünme sonrası toplam safsızlığı bulmak için her iki grubun Gini değerini veri oranına göre çarparız:

- **Gini (Rüzgar)** = (8/14 * 0.375) + (6/14 * 0.500)
- **Gini (Rüzgar)** ≈ 0.214 + 0.214 = **0.428**

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree): Örnek durum çalışması: Senaryo: Tenis Oynanacak mı?**

Elimizde 14 günlük bir geçmiş veri seti var. Hedefimiz (label), rüzgar durumuna bakarak tenis oynanıp oynanmayacağını tahmin etmek.

2. Özellik: Nem (Humidity)

Nem özelliğine göre veriyi böldüğümüzde (Yüksek ve Normal):

Dal	Dağılım	Gini Değeri
Yüksek (7 Gün)	3 Evet / 4 Hayır	$1 - [(3/7)^2 + (4/7)^2] \approx 0.489$
Normal (7 Gün)	6 Evet / 1 Hayır	$1 - [(6/7)^2 + (1/7)^2] \approx 0.245$

Ağırlıklı Gini: $(7/14 * 0.489) + (7/14 * 0.245) = \mathbf{0.367}$

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree): Örnek durum çalışması: Senaryo: Tenis Oynanacak mı?**

Elimizde 14 günlük bir geçmiş veri seti var. Hedefimiz (label), rüzgar durumuna bakarak tenis oynanıp oynanmayacağını tahmin etmek.

3. Özellik: Hava Durumu (Outlook) - CART İkili Bölme

CART algoritması her zaman ikili (Evet/Hayır) bölme yapar. En iyi ayrımı bulmak için "Hava Bulutlu mu?" sorusunu test edelim:

Dal	Dağılım	Gini Değeri
Evet (Bulutlu - 4 Gün)	4 Evet / 0 Hayır	$1 - [(4/4)^2 + (0/4)^2] = 0.000$ (Tam Saf!)
Hayır (Güneşli+Yağmurlu - 10 Gün)	5 Evet / 5 Hayır	$1 - [(5/10)^2 + (5/10)^2] = 0.500$

Ağırlıklı Gini: $(4/14 * 0.000) + (10/14 * 0.500) = \mathbf{0.357}$

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree): Örnek durum çalışması: Senaryo: Tenis Oynanacak mı?**

Elimizde 14 günlük bir geçmiş veri seti var. Hedefimiz (label), rüzgar durumuna bakarak tenis oynanıp oynanmayacağını tahmin etmek.

🏆 Sonuç: Kök Düğümün Seçilmesi

Tüm özelliklerin ağırlıklı Gini değerlerini karşılaştıralım:

- Rüzgar: 0.428
- Nem: 0.367
- **Hava Bulutlu mu?: 0.357 (En düşük safsızlık)**

Gini değerini (safsızlığı) **en çok düşüren** özellik "Hava Bulutlu mu?" sorusudur. Bu nedenle CART algoritması ağacı inşa etmeye bu soruyu **Kök Düğüm (Root Node)** yaparak başlar.

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- Sınıflandırma ve Regresyon Ağacı (CART-Classification and Regression Tree):
- Aşağıdaki veri seti için durum çalışmasını adım adım yapınız, decision tree yi çiziniz, tüm öz nitelikler için sırayla gini index' ini hesaplayarak ağacı oluşturunuz. (ipucu: weekend sütununu tablodan kaldırabiliriz neden ?)
- ÖDEV:

Weekend	Weather	Parents	Money	Decision
W1	Sunny	Yes	Rich	Cinema
W2	Sunny	No	Rich	Tennis
W3	Windy	Yes	Rich	Cinema
W4	Rainy	Yes	Poor	Cinema
W5	Rainy	No	Rich	Stay In
W6	Rainy	Yes	Poor	Cinema
W7	Windy	No	Poor	Cinema
W8	Windy	No	Rich	Shopping
W9	Windy	Yes	Rich	Cinema
W10	Sunny	No	Rich	Tennis

Denetimli(Gözetimli-Supervised) öğrenme, Karar Ağaçları (Decision Trees) Türleri

- **Karar Ağaçları Hiperparametreleri**

- **Bölünme Kriterleri (Splitting Criteria):** Algoritmanın bir düğümü bölerken hangi matematiksel formülü kullanacağını belirler, Sınıflandırma için genelde "gini" (Gini Safsızlığı) veya "entropy" (Bilgi Kazancı) seçilir. Regresyon için ise genelde "squared_error" (Hata Kareler Ortalaması - MSE) kullanılır.
- **max_depth (Maksimum Derinlik):** Ağacın kökten yaprağa kadar inebileceği en fazla katman sayısını belirler. Örneğin max_depth=3 derseniz, algoritma 3. seviyeden sonra soru sormayı bırakır ve yaprak düğüm oluşturur. Aşırı öğrenmeyi engellemenin en etkili yoludur.
- **min_samples_split (Bölünme İçin Minimum Örnek):** Bir düğümün alt dallara ayrılabilmesi için içinde bulunması gereken minimum veri sayısıdır. Örneğin min_samples_split=10 ise ve o düğüme sadece 9 veri düşmüşse, algoritma o düğümü daha fazla bölmez, yaprak düğüm ilan eder.
- **min_samples_leaf (Yaprakta Olması Gereken Minimum Örnek):** Bir dalın ucundaki nihai yaprak düğümde kalması gereken en az veri sayısıdır. Örneğin bu değeri 5 yaparsanız, algoritma sonunda sadece
- max_features (Maksimum Özellik Sayısı): Algoritma en iyi bölünmeyi ararken (Gini veya Entropi hesaplarken) eldeki özelliklerin (sütunların) tamamına bakmak yerine, rastgele seçilmiş belirli bir alt kümesine bakar. Bu işlem hem modeli hızlandırır hem de farklı özelliklerin de şans bulmasını sağlayarak modeli genelleştirir. (Genellikle Random Forest algoritmasında daha çok öne çıkar).

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Birden fazla karar ağacının bir araya gelerek bir orman oluşturduğu bir topluluk öğrenme (ensemble learning) yöntemidir,
- Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır. **Rastgele Orman (Random Forest),** bu sorunu çözmek için onlarca hatta yüzlerce karar ağacını bir araya getirerek bir "orman" oluşturan güçlü bir **Topluluk Öğrenmesi (Ensemble Learning)** algoritmasıdır.
- Bu algoritmanın amacı birden fazla karar ağacı oluşturup daha doğru ve istikrarlı bir tahmin elde etmek için o sonuçları birleştirmektir.

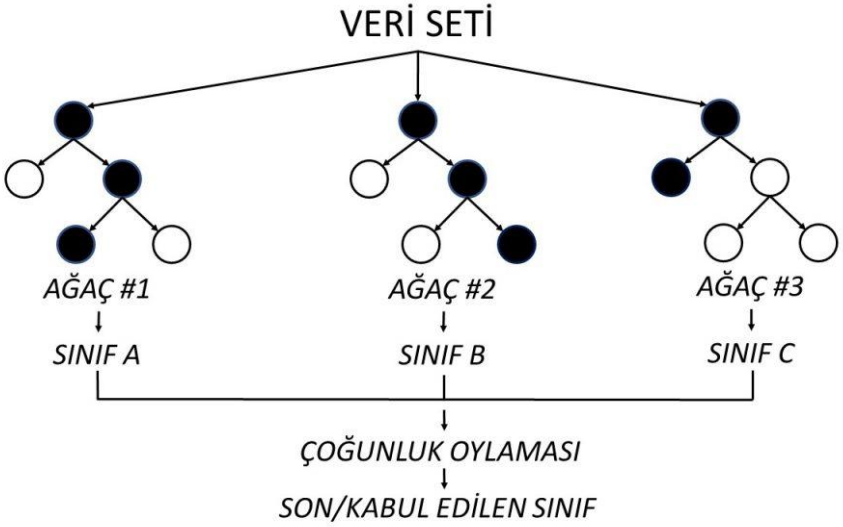

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır. **Rastgele Orman (Random Forest),** bu sorunu çözmek için onlarca hatta yüzlerce karar ağacını bir araya getirerek bir "orman" oluşturan güçlü bir **Topluluk Öğrenmesi (Ensemble Learning)** algoritmasıdır.

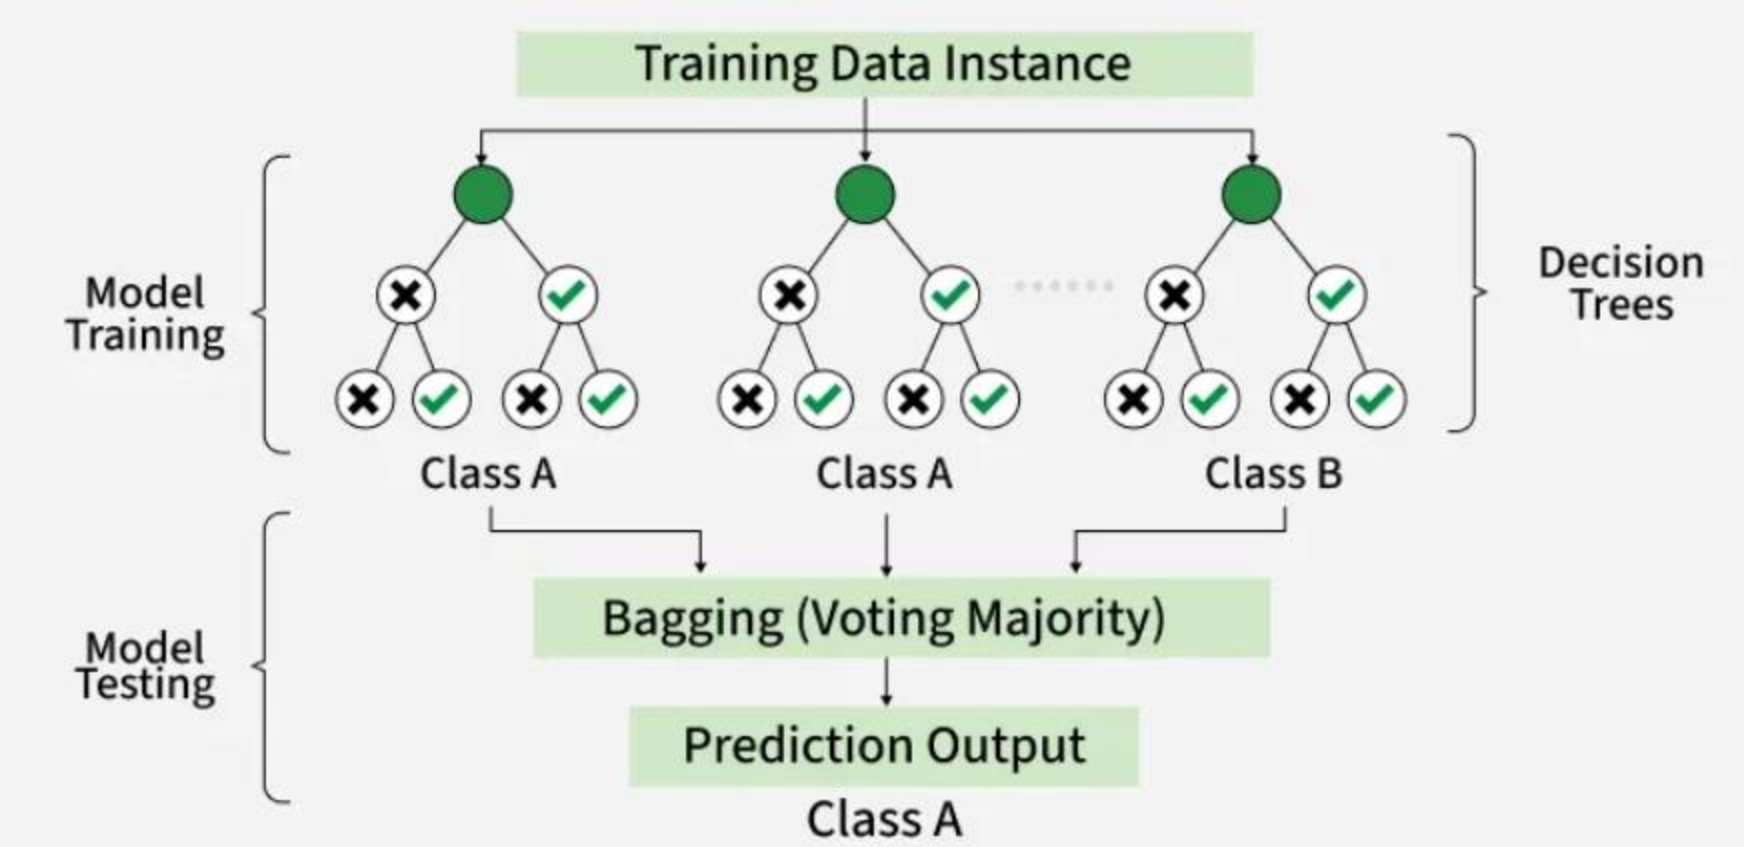

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır. **Rastgele Orman (Random Forest),** bu sorunu çözmek için onlarca hatta yüzlerce karar ağacını bir araya getirerek bir "orman" oluşturan güçlü bir **Topluluk Öğrenmesi (Ensemble Learning)** algoritmasıdır.
- Her karar ağacı, farklı alt örneklem (bootstrap sample) ve/veya alt özellikler (random subset of features) kullanılarak eğitilir
- **farklı alt örneklem (bootstrap sample):** Bootstrap sampling, orijinal bir veri setinden "yerine koyarak" (with replacement) rastgele yeni veri setleri türetme işlemidir.

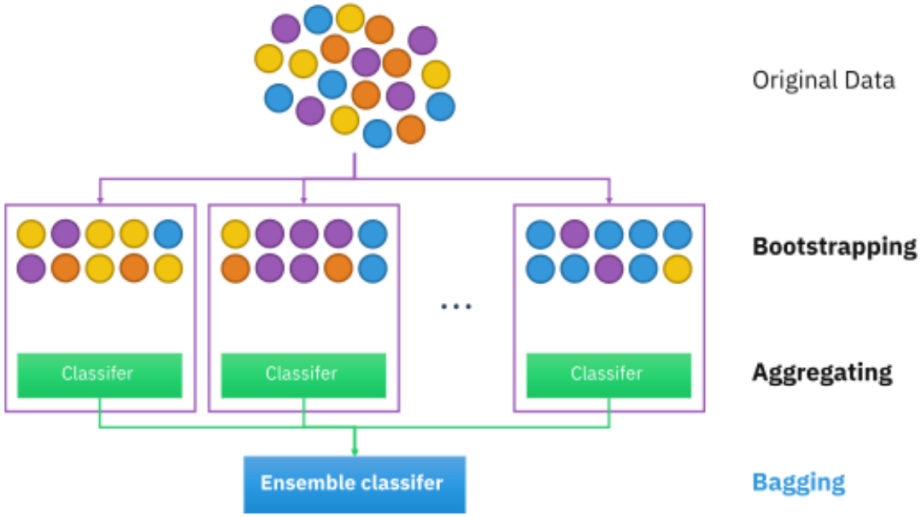

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Bootstrap sampling, orijinal bir veri setinden "yerine koyarak" (with replacement) rastgele yeni veri setleri türetme işlemidir.

Rasgele Orman

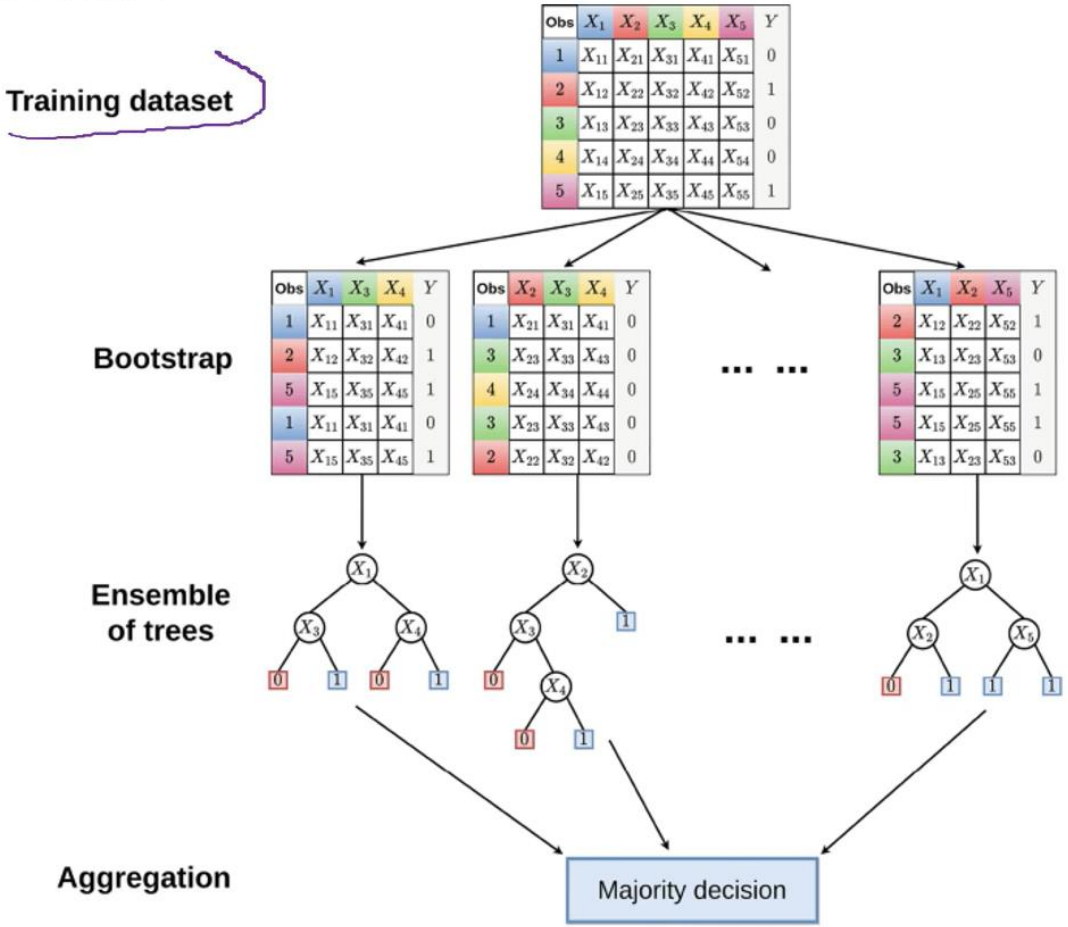

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır.

1. Bootstrap Sample (Farklı Alt Örneklem)

Orijinal veri setinden **yerine koyarak (with replacement)** rastgele seçim yapılmasıdır. Yani aynı satır birden fazla kez seçilebilir, bazı satırlar hiç seçilmeyebilir.

Orijinal Veri (10 öğrenci):

Öğrenci 1, 2, 3, 4, 5, 6, 7, 8, 9, 10

Ağaç 1 için bootstrap örneği (10 tane seç):

> 2, 5, 5, 1, 8, 3, 8, 10, 6, 2

→ 5 ve 8 **iki kez** seçildi; 4, 7, 9 **hiç** seçilmedi.

Ağaç 2 için bootstrap örneği:

> 1, 1, 4, 7, 3, 9, 6, 7, 10, 3

→ Tamamen farklı bir kombinasyon.

Amaç: Her ağaç farklı veri alt kümesiyle eğitildiği için **farklı bakış açıları** kazanır. Bu, modelin **aşırı öğrenmesini (overfitting)** engeller.

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır.

2. Random Subset of Features (Rastgele Özellik Alt Kümesi)

Her ağaçtaki **her dallanma noktasında**, tüm özellikler değil, rastgele seçilen bir alt küme değerlendirilir.

Diyelim ki 5 özelliğimiz var:

Özellik	Açıklama
X1	Ders çalışma süresi
X2	Devamsızlık sayısı
X3	Ödev notu
X4	Uyku süresi
X5	Gelir düzeyi

Her dallanmada örneğin **3 tanesi** rastgele seçilir (genelde $\sqrt{p}$ veya $p/3$):

Ağaç 1, Düğüm A: → {X1, X3, X5} seçildi → En iyi bölünme **X3** ile yapıldı

Ağaç 1, Düğüm B: → {X2, X4, X5} seçildi → En iyi bölünme **X2** ile yapıldı

Ağaç 2, Düğüm A: → {X1, X2, X4} seçildi → En iyi bölünme **X1** ile yapıldı

Amaç: Eğer bir özellik çok baskınsa (mesela X1 her zaman en iyi), normal durumda **tüm ağaçlar birbirine benzer** olurdu. Rastgele özellik seçimi sayesinde ağaçlar **birbirinden bağımsız ve çeşitli** olur.

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF):** Tek bir karar ağacının en büyük problemi aşırı öğrenmeye (overfitting) çok yatkın olmasıdır.

Özet: İkisi Birlikte Nasıl Çalışır?

```
Orijinal Veri (10 öğrenci, 5 özellik)
        |
   ┌────┴────┬──────────┐
   ▼         ▼          ▼
 Ağaç 1    Ağaç 2     Ağaç 3
 Farklı    Farklı     Farklı
 satırlar  satırlar   satırlar    ← Bootstrap Sample
 +         +          +
 Farklı    Farklı     Farklı
 özellik   özellik    özellik     ← Random Feature Subset
 seçimi    seçimi     seçimi
   |         |          |
   ▼         ▼          ▼
 Tahmin:   Tahmin:    Tahmin:
 Başarılı  Başarısız  Başarılı
   |         |          |
   └────┬────┴──────────┘
        ▼
  Çoğunluk Oyu → Başarılı ✓
```

Kısaca:

- **Bootstrap** → her ağaca **farklı veri satırları**
- **Random features** → her dallanmaya **farklı sütunlar**
- İkisi birlikte → ağaçlar arasında **çeşitlilik (diversity)** sağlar → daha güçlü ve genellenebilir model

Eğer "Rastgele Alt Uzay" yöntemini kullanmasaydık ne olurdu?

- Diyelim ki veri setinizde sonucu inanılmaz derecede iyi tahmin eden, çok baskın (dominant) bir özellik var.
- Tüm ağaçlara bölünme için bütün özellikleri sunarsanız, 100 ağacın 100'ü de kök düğümde (en tepede) ilk olarak o baskın özelliği seçecektir.
- Bu durumda elinizde 100 farklı ağaç değil, birbirine çok benzeyen, aynı şekilde davranan (yüksek korelasyonlu) 100 ağaç olurdu. Bu da "Topluluk Öğrenmesi"nin (Ensemble Learning) ruhuna aykırıdır.

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF) ağaçlar nasıl oluşturulur özet:**

Ormandaki her bir ağacın birbirinden farklı olmasını sağlamak için algoritma iki farklı rastgelelik adımı uygular:

- **Satır Bazlı Rastgelelik (Bootstrap Sampling):** Orijinal veri setinden rastgele seçimler (torbadan top çeker gibi, aynı veriyi birden fazla kez seçebilme izniyle) yapılarak her ağaç için yeni bir alt veri seti oluşturulur.
- **Sütun Bazlı Rastgelelik (Feature Sampling):** Bir ağaç düğümü bölüneceği zaman tüm özelliklere (sütunlara) bakılmaz. Sadece rastgele seçilmiş belirli sayıda özelliğe bakılarak en iyi bölünme aranır.

Bu iki adım sayesinde ormandaki hiçbir ağaç diğerinin kopyası olmaz. Her biri verinin farklı bir yönünde uzmanlaşır.

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF) karar aşaması:**

3. Sınıf Kararı Nasıl Verilir?

Ormandaki tüm ağaçlar bağımsız olarak büyütüldükten sonra, yeni bir veri geldiğinde karar verme aşamasına geçilir:

- **Sınıflandırma (Classification):** Her ağaç yeni veri için bir tahmin yapar (Örn: "Kanser" veya "Kanser Değil"). Nihai karar **Çoğunluk Oyu (Majority Voting)** ile verilir. En çok oyu alan sınıf kazanır.
- **Regresyon (Regression):** Eğer tahmin edilecek şey bir sayıysa (Örn: Ev fiyatı), tüm ağaçların ürettiği tahminlerin **Ortalaması (Average)** alınır.

Denetimli(Gözetimli-Supervised) öğrenme, Rastgele Orman (Random Forest)

- **Rastgele Orman (RF) hiperparametreleri:**

5. Önemli Hiperparametreler

Ormanın yapısını ve büyümesini kontrol etmek için kullanılan temel ayarlar şunlardır:

n_estimators: Ormandaki toplam karar ağacı sayısıdır. (Örn: 100 veya 500). Genellikle sayı arttıkça modelin performansı ve tutarlılığı artar, ancak eğitim süresi uzar.

max_features: Her düğüm bölünmesinde göz önünde bulundurulacak rastgele özellik (sütun) sayısıdır. Genellikle sınıflandırma için toplam özellik sayısının karekökü (sqrt), regresyon için ise özellik sayısının üçte biri tercih edilir.

max_depth: Ormandaki ağaçların inebileceği maksimum derinliktir. Random Forest zaten aşırı öğrenmeye dirençli olduğu için bu değer genelde karar ağaçlarındaki kadar kısıtlanmaz (hatta bazen limitsiz bırakılır).

min_samples_split / min_samples_leaf: Bir düğümün bölünmesi için veya bir yaprakta kalması gereken minimum veri sayısını belirler (Tekil karar ağaçlarındaki mantıkla tamamen aynıdır).

bootstrap: Alt veri setleri oluşturulurken rastgele çekim (bagging) yapılıp yapılmayacağını belirler. Standart olarak 'True' (Açık) gelir.

oob_score: Out-of-Bag örnekleri kullanılarak modelin genelleme başarısının hesaplanıp hesaplanmayacağını belirler (True/False).

- Haftaya: K-means, makine öğrenmesi değerlendirme metrikleri

- Doç. Dr. Musa AYDIN
- musa.aydin@samsun.edu.tr

Ofis No: 419